

UNIVERSIDAD
NACIONAL
DE COLOMBIA

Detección de evasión por puerta de vagón en sistemas BRT a través del análisis automático de video mediante un método de inteligencia artificial

Juan Camilo Hernández Ortiz

Universidad Nacional de Colombia

Facultad de Ingeniería

Departamento de Ingeniería de Sistemas e Industrial

Bogotá, Colombia

2026

Detección de evasión por puerta de vagón en sistemas BRT a través del análisis automático de video mediante un método de inteligencia artificial

Juan Camilo Hernández Ortiz

Tesis o trabajo de investigación presentado como requisito parcial para optar al título de:

Magíster en Ingeniería - Ingeniería de Sistemas y Computación

Director (a):

César Augusto Pedraza Bonilla, Ph.D

Departamento de Ingeniería de Sistemas e Industrial

Línea de Investigación:

Machine Learning / Data Science

Universidad Nacional de Colombia

Facultad de Ingeniería

Departamento de Ingeniería de Sistemas e Industrial

Bogotá, Colombia

2026

Dedicatoria

A Lindsey y Lucy, por haberme acompañado en diferentes etapas de la maestría y el desarrollo de este trabajo, y a todos mis seres amados que me alegran la existencia.



Agradecimientos

Agradezco a mis padres por haberme apoyado y educado; a mi hermana, por acompañarme en esta vida; y a Fabio, Celeste y todos mis amigos, quienes me hacen un ser feliz.

Agradezco a mi director por el apoyo brindado y a la ingeniería por abrirme las puertas al mundo y por todo lo que eso me ha dejado.

Resumen

Detección de evasión por puerta de vagón en sistemas BRT a través del análisis automático de video mediante un método de inteligencia artificial

Ante la problemática crítica de la evasión del pago de pasajes en el sistema TransMilenio, que alcanza tasas cercanas al 15% y carece de mecanismos de medición automatizados estandarizados, este trabajo desarrolla un método computacional basado en Inteligencia Artificial y Visión por Computador para la detección automática de ingresos ilegales por las puertas de los vagones. Mediante la construcción de un conjunto de datos propio con 1.800 clips de video y una metodología que integra técnicas de segmentación, detección de objetos, seguimiento de trayectorias y análisis de las mismas, se exploraron sistemáticamente diversas configuraciones hasta determinar una arquitectura óptima; los resultados demostraron que el método propuesto cuantifica eficazmente los eventos de evasión con estabilidad tanto en clips cortos como en videos continuos, validándose como una herramienta tecnológica efectiva para apoyar las estrategias de control y mitigación de este fenómeno en sistemas de transporte masivo tipo BRT.

Palabras clave: Evasión de tarifas, TransMilenio, Detección de Colados, Sistemas BRT, Inteligencia Artificial, Visión por Computador, Aprendizaje Profundo, Análisis de Video.

Abstract

Fare Evasion Detection at BRT Vehicle Doors through Automatic Video Analysis Using an Artificial Intelligence Method

Given the critical problem of fare evasion in the TransMilenio system, which reaches rates close to 15% and lacks standardized automated measurement mechanisms, this work develops a computational method based on Artificial Intelligence and Computer Vision for the automatic detection of illegal entries through the vehicle doors. By constructing a proprietary dataset consisting of 1,800 video clips and employing a methodology that integrates segmentation techniques, object detection, trajectory tracking, and trajectory analysis, various configurations were systematically explored until an optimal architecture was identified. The results demonstrate that the proposed method effectively quantifies fare evasion events with stable performance in both short clips and continuous video streams, validating it as an effective technological tool to support control and mitigation strategies for this phenomenon in BRT-type mass transit systems.

Keywords: Fare Evasion, TransMilenio, Fare Evasion Detection, BRT Systems, Artificial Intelligence, Computer Vision, Deep Learning, Video Analysis.

Contenido

Pág.

1. Introducción 12

1.1 Planteamiento del Problema 14

1.2 Justificación 15

1.3 Objetivos 16

1.3.1 Objetivo General 16

1.3.2 Objetivos Específicos 16

2. Marco Teórico 17

2.1 Evasión 17

2.1.1 Evasión Cruzando la Calle (caso 1) 17

2.1.2 Evasión por Troncal Exclusiva (caso 2) 18

2.1.3 Evasión por Llegada de Bus (caso 3) 18

2.1.4 Consideraciones 19

2.2 Inteligencia Artificial 20

2.2.1 Aprendizaje Automático (Machine Learning) 20

2.3 Redes Neuronales Convolucionales (CNN) 21

2.3.1 Funcionamiento de las CNN 22

2.4 Algoritmos Usados en Detección de Personas y Acciones 24

2.4.1 Algoritmos de Detección de Personas 30

2.4.2 Algoritmos de Seguimiento de Objetos 31

2.4.3 Algoritmos de Reconocimiento de Acciones Humanas. 32

3. Trabajos Relacionados 34

4. Metodología 37

4.1 Dataset 39

4.1.1 Características de los Videos 40

4.2 Preparación de los Datos 41

4.3 Modelos y Técnicas Implementadas 43

4.3.1 Detección de la Estación 43

4.3.2 Detección de Personas 46

4.3.3 Tracking de Personas 48

4.3.4 Detección de Acciones 52

4.3.5 Análisis de Trayectorias 54

4.4 Refinamiento 56

4.5 Exploración de Parámetros 59

4.5.1 Análisis de la Mejor Configuración 62

4.5.2 Rendimiento de la Mejor Configuración 64

5. Resultados 67

5.1 Análisis de la Matriz de Confusión 68

5.2 Análisis de Métricas de Rendimiento 69

5.3 Alcance y Limitaciones 71

6. Conclusiones y Trabajo Futuro 73

6.1 Conclusiones 73

6.2 Trabajo Futuro 74

Bibliografía 76

Lista de figuras

Figura 2-1 Casos de evasión por puerta de vagón 18
Figura 2-2 Ejemplo de evasión en hora pico 19
Figura 2-3 Red neuronal convolucional 22
Figura 4-1 Metodología 38
Figura 4-2 Ejemplos de grabaciones en puertas de vagón 40
Figura 4-3 Ejemplos de segmentación de instancias 43
Figura 4-4 Ejemplo de etiquetado de estaciones con Roboflow 44
Figura 4-5 Ejemplos de predicción para estación completa 45
Figura 4-6 Ejemplos de predicción para estación sin plataforma 46
Figura 4-7 Ejemplos de segmentación de instancias 47
Figura 4-8 Ejemplo de implementación de YOLO al contexto específico 48
Figura 4-9 Ejemplo de implementación de tracker al contexto específico 49
Figura 4-10 Comparación de desempeño de trackers en dataset MOT27 y MOT20 50
Figura 4-11 Pérdida de objetos pequeños en implementación de YOLO-pose 53
Figura 4-12 Detectando evasión aplicando el método desarrollado 56
Figura 4-13 Escenarios presentados en el dataset WiderPerson 58
Figura 4-14 Gráfica del F1-Score para cada una de las configuraciones exploradas 61
Figura 4-15 Ranking de las 20 mejores configuraciones exploradas 61
Figura 4-16 Matriz de confusión de conteos exactos para la mejor configuración 64
Figura 4-17 Matriz de confusión por eventos de evasión para la mejor configuración 65
Figura 5-1 Matriz de confusión de conteos exactos en la validación final 67
Figura 5-2 Matriz de confusión por eventos de evasión en la validación final 68

Lista de tablas

Tabla 2-1 Trabajos realizados usando algoritmos de IA para análisis de imágenes o videos relacionados con detección de acciones, personas u objetos 26
Tabla 2-2 Ranking de algoritmos usados para detección de personas 30
Tabla 2-3 Ranking de algoritmos usados para seguimiento de objetos 31
Tabla 2-4 Ranking de algoritmos usados para detección de acciones/poses 32
Tabla 4-1 Metadatos de los clips que conforman el dataset 41
Tabla 4-2 Parámetros usados para la configuración de los trackers 50
Tabla 4-3 Reglas aplicadas a las trayectorias para la detección de evasión 54
Tabla 4-4 Parámetros explorados con grid search 59
Tabla 4-5 Atributos de la mejor configuración explorada 62
Tabla 4-6 Métricas de evaluación de la mejor combinación de parámetros 66
Tabla 5-1 Métricas de la evaluación final 68

1. Introducción

La ciudad de Bogotá cuenta con un sistema de transporte masivo conocido como TransMilenio, de tipo Bus de Tránsito Rápido (Bus Rapid Transit, BRT), el cual constituye el principal medio de transporte para los ciudadanos. En 2018 se llevó a cabo un estudio pionero con el fin de comprender el comportamiento de los evasores de tarifa en este sistema de transporte público. Dicho estudio encontró que aproximadamente el 15% de los usuarios evadían el pago del pasaje durante los días laborables (Guzman, Arellana, & Camargo, 2021). Este hallazgo evidenció la magnitud del problema de la evasión en TransMilenio y resaltó la necesidad urgente de abordarlo de manera efectiva. Es importante señalar que las empresas de transporte público, conscientes de las pérdidas significativas que representa la evasión de tarifas, han mostrado un genuino interés en resolver este problema (Barabino, Lai, & Olivo, 2020). La evasión no solo impacta los ingresos del sistema, sino que también crea un ambiente de impunidad y desafío a las normas, afectando negativamente la experiencia de viaje de los usuarios.

La inteligencia artificial ofrece un enfoque prometedor para tratar este problema, ya que la capacidad de procesar grandes volúmenes de datos de video en tiempo real e identificar comportamientos, proporciona información valiosa que podría ayudar a mejorar la seguridad y eficiencia en estos sistemas de transporte público. A pesar de que esta problemática ha sido reconocida como importante, hasta el momento solo se han desarrollado tres proyectos que relacionan el uso de inteligencia artificial para detectar la evasión mediante el análisis de video. El primero es un estudio que aborda la problemática de la evasión del pasaje desde un enfoque de caso de estudio para TransMilenio, proponiendo un prototipo de sistema de control y monitoreo basado en tratamiento de imágenes. El uso de tecnologías visuales se plantea como una herramienta de apoyo

operacional, más que como un desarrollo o aporte en inteligencia artificial o análisis avanzado de video (Burgos, Velásquez, & Rosero, 2018). El segundo proyecto también se desarrolla en el contexto de TransMilenio, pero enfocándose específicamente en detectar y cuantificar a los infractores en los torniquetes a través de técnicas avanzadas de visión por computador e IA (Rodríguez Peraza, 2024). A pesar de tener un propósito común, este escenario exige enfoques y soluciones tecnológicas diferentes. Por parte de TransMilenio, desde el año 2021 se ha venido desarrollando el Sistema Inteligente de Detección de Eventos de Seguridad en TransMilenio (SIDEST), que usa IA para detectar la evasión en todas sus modalidades. Este sistema aún se está desplegando en las estaciones del sistema (TransMilenio S.A., 2023a). Como tal, no se comparten detalles técnicos del algoritmo que se usa, ya que esto es una contratación privada.

Dada la especificidad de esta problemática, este trabajo explora y adapta algoritmos de IA utilizados en contextos similares para desarrollar un método capaz de detectar la evasión en las puertas de los vagones. Para ello, se construyó un conjunto de datos con 1.800 clips extraídos de videos grabados en puertas de vagones en el sistema TransMilenio: 1.200 con eventos de evasión y 600 de control (sin evasión). Este trabajo integra técnicas de visión artificial para la segmentación del entorno, detección de personas y seguimiento de trayectorias (tracking) con el fin de clasificar eventos de evasión. Tras una exploración sistemática de parámetros (grid search) sobre 40 configuraciones, se determinó la arquitectura óptima. Estos clips utilizados para la validación final incluyen metadatos esenciales que permitieron contrastar los datos reales con los obtenidos por el método.
Los resultados confirman un desempeño destacable en la cuantificación de ingresos ilegales, manteniendo la estabilidad tanto en clips cortos como en videos continuos de hasta 20 minutos. Este rendimiento es especialmente relevante dada la complejidad de las escenas y la variabilidad en los patrones de movimiento de los usuarios.

1.1 Planteamiento del Problema

TransMilenio carece de un método estándar para medir la evasión, lo que ha llevado a una combinación de diferentes enfoques. Actualmente, utilizan una metodología que combina un enfoque manual, con personas ubicadas en las estaciones que cuentan a ojo cuántas personas ingresan ilegalmente, tecnologías como revisión del sistema de vigilancia DTS/BRT y el sistema de inteligencia artificial SIDEST (TransMilenio S.A., 2022; TransMilenio S.A., 2023a). Sin embargo, la implementación de esta solución de inteligencia artificial abarca 51 de las 83 estaciones que cuentan con videovigilancia en el sistema (TransMilenio S.A., 2024).

A pesar de los avances en la implementación de un sistema de inteligencia artificial para detectar la evasión, no se conocen las características técnicas del método utilizado por TransMilenio, ya que este fue una contratación de software con la UNIÓN TEMPORAL MOVILIDAD INTELIGENTE en 2021, bajo el mecanismo de concurso de méritos (TransMilenio S.A., 2023a). En los informes de la empresa, la única información técnica encontrada de este desarrollo, referencia el uso de una red neuronal de la familia EfficientDet (TransMilenio S.A., 2023b). En el prototipo propuesto por (Burgos, Velásquez, & Rosero, 2018) no se comparte información detallada sobre el algoritmo utilizado para detectar la evasión por puerta de vagón, solo se proporcionan los algoritmos principales usados.

Estas deficiencias tienen diversas consecuencias. La falta de un método estandarizado de medición y la limitada implementación del sistema de IA pueden llevar a mediciones inexactas de la evasión, lo que dificulta la toma de decisiones informadas para abordar el problema (TransMilenio S.A., 2022; TransMilenio S.A, 2023a).

1.2 Justificación

La evasión del pago del pasaje en el transporte público es un problema que afecta a numerosos sistemas de transporte en todo el mundo, generando pérdidas tanto para las empresas operadoras como para el Estado, que a menudo subsidia a estas empresas (Bahamondes, 2019). La evasión de tarifas en sistemas de transporte masivo se ha convertido en un desafío significativo debido a la vulnerabilidad inherente de estos sistemas. Medir y prevenir este fenómeno resulta complicado debido a la ausencia de métodos estándar para estimar el cumplimiento de las tarifas y la evasión (Barabino, Lai, & Olivo, 2020).

En el caso específico de Bogotá, en TransMilenio el índice de evasión de tarifas se encontró entre el 13.08% y 15.57%, incrementándose domingos – festivos (24.40%) y sábados (19.25%) (TransMilenio S.A., 2024). En el reporte de evasión más reciente no se mencionan las pérdidas económicas, pero en 2021 este índice de evasión fue del 15.4% y del 25.2% durante los fines de semana, porcentajes similares a los registrados actualmente. Ese año, estas cifras representaron aproximadamente dos millones de evasores por semana, lo que ocasionó pérdidas económicas significativas para la ciudad, estimadas en alrededor de 250 mil millones de pesos anuales (Guzman, Arellana, & Camargo, 2021).

Esta situación desafiante requiere soluciones que no solo reduzcan las pérdidas financieras, sino que también mejoren la equidad y la eficiencia del transporte público. Abordar esta problemática no solo tiene implicaciones económicas y sociales, sino que también representa un terreno fértil para la aplicación de la inteligencia artificial (IA). El desarrollo de un sistema automático de análisis de video para detectar la evasión por puerta de vagón en TransMilenio no solo contribuiría a resolver un problema real, sino que también impulsaría el avance técnico y práctico de la IA en este campo, permitiendo su implementación en otros sistemas BRT que también pueden presentar problemas similares

de evasión por puerta de vagón, como el MIO en Cali, Transmetro en Barranquilla, Metroplus en Medellín y Megabús en Pereira.

1.3 Objetivos

1.3.1 Objetivo General

Desarrollar un método computacional para la detección automática de evasión por puertas de vagones en sistemas BRT mediante el análisis de video.

1.3.2 Objetivos Específicos

1. Explorar diversos métodos de inteligencia artificial para la detección de evasión en las puertas de los vagones de TransMilenio mediante una revisión de la literatura.
2. Implementar un método de inteligencia artificial para la detección de evasión en las puertas de los vagones de TransMilenio, evaluando su aplicabilidad al contexto específico.
3. Evaluar el método de inteligencia artificial implementado mediante la revisión de los resultados obtenidos del análisis de un dataset de videos grabados en las puertas de los vagones.

2. Marco Teórico

2.1 Evasión

Dado que este trabajo se centra en abordar el fenómeno de la evasión a través de entradas ilegales por las puertas laterales de los vagones en estaciones de sistemas BRT, resulta pertinente analizar las características observadas en un conjunto de videos capturados por cámaras ubicadas en los laterales de las estaciones del sistema de transporte público TransMilenio, orientadas hacia las puertas de los vagones. Este análisis permite comprender cómo se presenta la evasión en esta modalidad y cuáles son los aspectos clave que deben considerarse al momento de desarrollar un método capaz de detectarla de manera efectiva.

Cualquier persona que ingrese a la estación y no lo haga desde un bus, es considerada como una entrada ilegal. En la revisión de los videos se encontró que existen 3 formas comunes de hacerlo.

2.1.1 Evasión Cruzando la Calle (caso 1)

En esta forma, la persona aprovecha que hay un espacio entre carros, atraviesa la calle y salta o sube a la estación, es la forma más común en que las personas ingresan ilegalmente al sistema.

2.1.2 Evasión por Troncal Exclusiva (caso 2)

La persona se desplaza o aparece por uno de los lados de la troncal exclusiva; en este caso, no cruza la calle y puede ingresar por el frente o por la parte trasera de la estación.

2.1.3 Evasión por Llegada de Bus (caso 3)

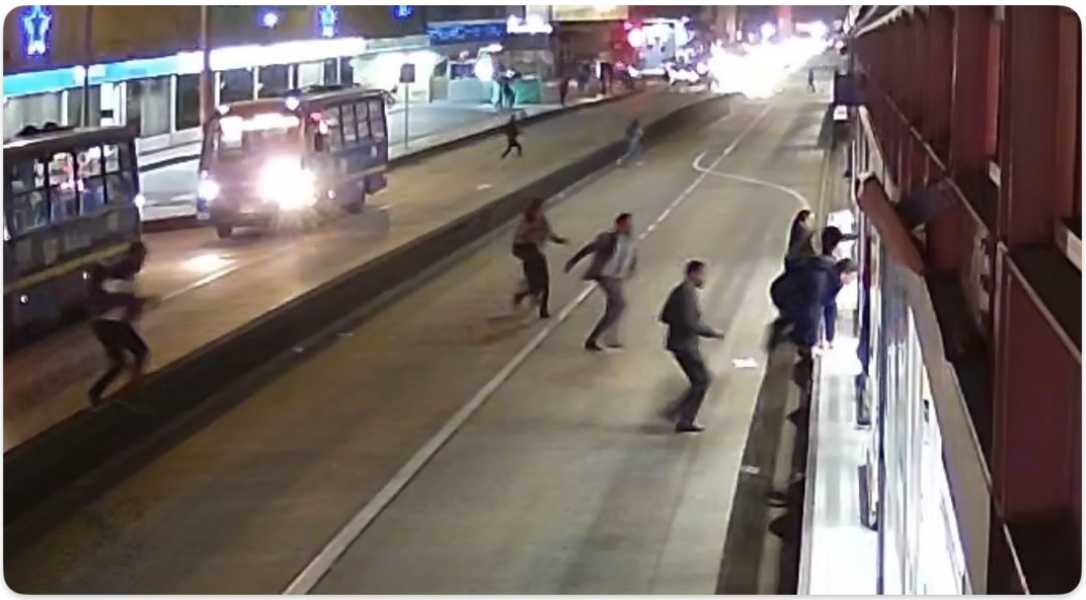
La persona puede cruzar la calle o caminar por la troncal exclusiva; sin embargo, en este caso aprovecha el momento en que el bus está abordando o desabordando pasajeros para subir por el borde de la estación e ingresar a esta o directamente al bus.

Figura 2-1 Casos de evasión por puerta de vagón



Fuente: elaboración propia

Figura 2-2 Ejemplo de evasión en hora pico



Fuente: elaboración propia

2.1.4 Consideraciones

Como se observa en la **Figura 2-1**, los comportamientos de las personas que ingresan de manera ilegal pueden ser complejos, ya que en algunos casos ocurren múltiples acciones simultáneamente y las poses o movimientos pueden resultar difíciles de reconocer.

Al revisar los videos, y como se muestra en la **Figura 2-2**, se evidencia que en horas pico, en algunas estaciones las personas ingresan ilegalmente en grupos de hasta 16 personas en menos de 20 segundos. Esta situación resulta compleja, ya que las personas pueden cruzarse y generar confusión. Esto es relevante para el método a desarrollar, pues podría afectar la precisión en el conteo de eventos de evasión.

2.2 Inteligencia Artificial

La inteligencia artificial (IA) hace referencia a la capacidad de las máquinas para poder aprender de datos mediante algoritmos y tomar decisiones similares a las humanas. Es una rama de la computación que simula el comportamiento inteligente (Cabanelas Omil, 2019). A diferencia de las personas, los dispositivos basados en IA pueden analizar grandes cantidades de información sin descanso y con una proporción de errores significativamente menor que los humanos en tareas similares (Rouhiainen, 2018).

La inteligencia artificial es muy versátil y puede aplicarse a múltiples situaciones, tales como el reconocimiento de imágenes, la clasificación y etiquetado de las mismas, la mejora del rendimiento de estrategias algorítmicas comerciales, el mantenimiento predictivo, la detección y clasificación de objetos, protección contra amenazas de seguridad cibernética, optimización de recursos, predicción meteorológica y el procesamiento del lenguaje natural, entre otros (Rouhiainen, 2018; de Titto & Savino, 2023).

2.2.1 Aprendizaje Automático (Machine Learning)

El aprendizaje automático es una de las áreas fundamentales de la inteligencia artificial, ya que permite a las computadoras aprender a partir de los datos sin ser programadas de forma explícita. Este enfoque se basa en la identificación de patrones en los datos para realizar predicciones y generar recomendaciones. A diferencia de los primeros sistemas computacionales, los modelos actuales aprenden de la experiencia y pueden adaptarse a distintos contextos, ofreciendo resultados personalizados a los usuarios. El aprendizaje automático se clasifica principalmente en tres categorías: supervisado, no supervisado y por refuerzo (Rouhiainen, 2018).

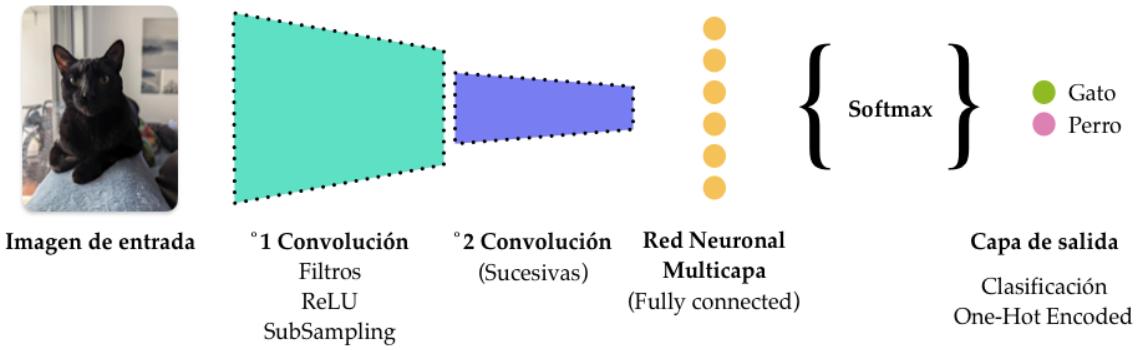
Aprendizaje Profundo (Deep Learning)

El Deep Learning es un subcampo poderoso de la IA y una rama del aprendizaje automático. Generalmente es usado para resolver problemas complejos en los cuales se analizan grandes volúmenes de datos, empleando redes neuronales para identificar relaciones y patrones complejos en los datos. Este enfoque imita la creación de patrones y el procesamiento de datos del cerebro humano para tomar decisiones y puede aprender sin ser supervisado a partir de datos sin etiquetas o que no están estructurados. Sin embargo, su implementación requiere enormes conjuntos de datos y una gran capacidad de procesamiento (Cabanelas Omil, 2019).

2.3 Redes Neuronales Convolucionales (CNN)

Una red neuronal convolucional (CNN), que forma parte del deep learning, es un tipo específico de red multicapa utilizada para procesar imágenes. Estas redes imitan cómo los humanos distinguen objetos basándose en diversas características como color, bordes y sombras. Las CNN están compuestas por capas de convolución, reducción (max pooling) y capas densas (fully connected). Las capas iniciales extraen características clave, mientras que las capas densas clasifican el objeto (Badillo, Hernández, Narváez, & Trillos, 2021). Las redes de neuronas convolucionales tienen neuronas dispuestas en tres dimensiones: anchura, altura y profundidad. Aquí, las neuronas de una capa solamente están conectadas a una pequeña región de la capa anterior (Bonilla Carrión, 2020). A diferencia de las redes neuronales convencionales, que se vuelven ineficientes al procesar imágenes de alta resolución debido a la gran cantidad de conexiones requeridas, las redes neuronales convolucionales abordan este problema de manera eficiente (Durán Suárez, 2017).

Figura 2-3 Red neuronal convolucional



Fuente: elaboración propia

2.3.1 Funcionamiento de las CNN

Capa de Agrupación (Pooling Layer)

La capa de pooling sigue a la capa de convolución en una CNN. Después de extraer características en la capa de convolución, el siguiente paso es usar estas características para la clasificación de imágenes (Durán Suárez, 2017). Esto ayuda a mejorar el entrenamiento de la red y a eliminar el ruido de la imagen. Sin embargo, es importante no exagerar con el uso del max pooling, ya que podría eliminar características significativas junto con el ruido. Estas capas tienen como objetivo reducir el tamaño de la imagen, preservando sus características principales (Badillo, Hernández, Narváez, & Trillos, 2021).

Capa Completamente Conectada (Fully Connected Layer)

Las capas completamente conectadas en una red de neuronas convencional están interconectadas a las neuronas de la capa anterior. A diferencia de estas últimas, que se conectan a una región local de la entrada y comparten parámetros, las capas

completamente conectadas tienen un gran número de conexiones. Estas capas agrupan los datos obtenidos hasta ese momento para su posterior clasificación (Bonilla Carrión, 2020).

Función de Activación

Estas funciones de activación son esenciales en las capas de convolución y completamente conectadas de las CNN. Estas funciones, como la sigmoidal (para clasificación binaria) y la softmax (para clasificación multiclase), asignan probabilidades a las salidas de la red. La función ReLU (Rectified Linear Unit) es ampliamente utilizada para evitar el problema del desvanecimiento del gradiente. Una variante mejorada de ReLU es Leaky ReLU, que permite que las activaciones negativas no se vuelvan cero, lo que permite un aprendizaje más continuo y poderoso (Badillo, Hernández, Narváez, & Trillos, 2021).

Entrenamiento

Para poder entrenar una red neuronal se debe ejecutar un proceso iterativo en el que los filtros en las capas de convolución y los pesos en las capas de clasificación se ajustan para minimizar las diferencias entre los resultados de la red y las etiquetas de verdad. Este proceso implica la propagación hacia adelante (forward propagation), donde la información se pasa a través de la red para generar una predicción, y la retroalimentación (back propagation), donde los errores se corrigen ajustando los parámetros de la red. Estas etapas se repiten en múltiples iteraciones durante varias épocas, permitiendo que la red aprenda de los datos y mejore sus predicciones con el tiempo (Badillo, Hernández, Narváez, & Trillos, 2021).

2.4 Algoritmos Usados en Detección de Personas y Acciones

La inteligencia artificial ha tenido un aumento importante en su popularidad en los últimos años gracias a su amplio espectro de aplicaciones. En el ámbito de los sistemas de transporte masivo, se ha explorado su implementación para analizar imágenes y vídeos capturados por cámaras instaladas en estaciones y vagones, con el fin de identificar entradas ilegales de personas (Burgos, Velásquez, & Rosero, 2018). En el campo de la inteligencia artificial, se encuentran diversos algoritmos que, implementados adecuadamente, podrían ofrecer contribuciones significativas a la resolución de este problema particular.

No existe un algoritmo específico que sea universalmente efectivo para detectar la entrada ilegal de personas en estos sistemas, por lo que resulta importante determinar qué herramientas y algoritmos son los más adecuados para abordar este desafío. Teniendo en cuenta esto, el procesamiento de video e imágenes para detección y seguimiento de objetos es importante para tomar enfoques tradicionales como sustracción de fondo, flujo óptico y diferenciación de cuadros, así como la implementación de CNN que son enfoques basados en el aprendizaje profundo (Chavan, Chaudhari, & Ramteke, 2023).

En el campo de la detección de personas mediante inteligencia artificial, se han desarrollado y aplicado con éxito diversos algoritmos. Entre los más destacados se encuentran las CNN, que resultan efectivas para la identificación de objetos, y los algoritmos de seguimiento de objetos, que posibilitan el monitoreo en tiempo real de la ubicación y el movimiento de las personas (Purwono, et al., 2023). Identificar a las personas es un parte crucial, pero también analizar el contexto y la pose que está tomando, es importante para poder determinar el ingreso al sistema, por lo tanto, pueden ser útiles métodos de agregación de características a nivel semántico mediante el uso de técnicas de aprendizaje profundo que no solo permitan identificar objetos, sino entender el contexto

de lo que están haciendo (Jeevidha, Saraswathi, & Vishnuprasad, 2023). La combinación de estos algoritmos puede proporcionar una solución sólida para abordar el desafío de la entrada ilegal en sistemas de transporte masivo.

Se ha observado la existencia de varios modelos basados en el aprendizaje profundo (DL) destinados a tareas como la detección genérica de objetos, la detección específica de objetos y el seguimiento de estos. Estos modelos se aplican tanto de manera individual como en combinación para abordar la detección y el seguimiento de objetos. En algunos casos, se utilizan para detectar peatones, lo cual es relevante para el tema en cuestión (Pal, Pramanik, Maiti, & Mitra, 2021). Se ha constatado que, en aplicaciones de video, las CNN sobresalen sobre otras técnicas de aprendizaje automático tradicionales (Ma & Salcic, 2021).

Dentro de los algoritmos de redes neuronales convolucionales, se encontró que el algoritmo YOLO ha demostrado su efectividad para ser aplicado a múltiples casos en el análisis de video cuando se le compara con enfoques tradicionales (Valarmathi, et al., 2023). Con YOLO se pueden generar cajas delimitadoras para las áreas de interés en un video y complementar con más técnicas para maximizarlo, por ejemplo, se puede usar en conjunto con la librería de OPENCV para usar un algoritmo de seguimiento de personas (Gündüz & Işık, 2023). También existen sistemas de Reconocimiento de Actividades Humanas (HAR, por sus siglas en inglés) a partir de colecciones de datos de video, con la finalidad de identificar acciones humanas en videos de diversas resoluciones, posturas humanas y la presencia de múltiples objetos cercanos (Augusta Kani & Geetha, 2023).

En la **Tabla 2-1** podemos ver los trabajos relacionados con el tema de análisis de video e imágenes desde el 2018 a la actualidad. Se analizaron las variables de tipos de datos, si se usaron para detectar objetos o personas, si estaban en la rama del Deep Learning y si hacían uso de redes neuronales convolucionales.

Tabla 2-1 Trabajos realizados usando algoritmos de IA para análisis de imágenes o videos relacionados con detección de acciones, personas u objetos

	Algoritmos	**Uso**	**Datos**	**Detección**	**Deep Learning**	**CNN**
(Burgos, Velásquez, & Rosero, 2018)	OpenCV, Algoritmo Canny, Algoritmo Minimum Bounding Box, Algoritmo Haar Cascade, Algoritmo K-Nearest Neighbors (KNN)	Caso de estudio para analizar evasión por puerta de vagón en TransMilenio	video	personas	X	
(Hsiao & Tsai, 2018)	Horn and Schunk (HS) y Lucas Kanade (LK), Pyramidal LK (PLK), SIFT (Scale-Invariant Feature Transform) y SURF (Speeded-Up Robust Features)	Visión por computadora para la detección de objetos, seguimiento de objetos y cálculo de profundidad	video	objetos	X	
(Yang & Chen, 2019)	Detector de Caja Múltiple de Disparo Único (D-SSD), Marco de Seguimiento Visual (Kalman Basado en Filtros de Correlación de Núcleo, K-KCF)	Seguimiento visual denso de multitudes basado en aprendizaje profundo	video	personas	X	X
(Nguyen, Pham, Ha, & Jeon, 2019)	CDNet 2014, Red de Tripletes.	Detección y cambios de movimiento	video	objetos	X	X
(Ghaywate, Vyas, Telang, & Mangale, 2019)	CNN, background subtraction, optical flow, Lucas-Kanade Optical Flow, FlowNet	Detección de movimiento significativo en datos de video de vigilancia	video	personas	X	X

(Hanavi & Hidayat, 2020)	CNN, Análisis de Video Inteligente	Detección de objetos sospechosos en sistemas de vigilancia	video	personas	X	X
(Padhi, Sahoo, & Maity, 2021)	TensorFlow, Detectores de un Solo Disparo (SSD	Detección de objetos y seres humanos en imágenes	imagen	personas	X	X
(Challa & Rao, 2021)	CNN, Histogramas de Gradientes Orientados (HOG), Máquinas de Vectores de Soporte (SVM), AdaBoost y Modelo Basado en Partes Deformables (DPM).	Detección y localización en imágenes	imagen	objetos	X	X
(Zhang, et al., 2022)	Análisis de Comportamiento Basado en Visión, Algoritmos de Detección de Anomalías	Implementación de sistemas avanzados de vigilancia para mejorar la seguridad en sistemas ferroviarios	video	personas	X	X
(Liu, et al., 2022)	Algoritmo basado en YOLOv5	Análisis y detección de objetos anómalos (AOAD) dentro de un autobús	video	objetos	X	X
(Li, 2022)	Truncated Weighted Robust Principal Component Analysis (TW-RPCA), Salience Convolution Neural Network (Salience CNN)	Mejorar la capacidad de generalización de los métodos de detección de objetos en movimiento.	video	objetos	X	X

(Adimoolam, Mohan, A., & Srivastava, 2022)	Video Surveillance, Video Analytics, Densely Feature selection Convolutional neural Network – Hyper Parameter tuning (DFCN-HP)	Mejorar la precisión y velocidad en la detección y seguimiento de múltiples objetos en entornos estáticos y dinámicos	video	objetos	X	X
(Kumar & Bhatt, 2022)	YOLO, OpenCV	sistema puede identificar y trazar límites alrededor de objetos como personas, bicicletas, autos, buses y botes en imágenes o videos, pregrabados o en tiempo real	imagen/ video	objetos/ personas	X	X
(Gupta, et al., 2023)	YOLO (You Only Look Once), SSD (Single Shot Multibox Detector), Faster R-CNN	Detección de humanos utilizando técnicas de aprendizaje profundo.	video	personas	X	X
(Wang, et al., 2021)	YOLOv2-tiny, marco de detección paralela ARO	Análisis de videos de cámaras de seguridad	video	personas	X	X
(Valarmathi, et al., 2023)	Faster-RCNN (F-RCNN), Single Shot Detector, Region-based Fully Convolutional Network, YOLOv3 (You Only Look Once)	Reconocimiento humano en imágenes tomadas por drones en lugares de desastres naturales	imagen	personas	X	X
(Ghahreman nezhad, Shi, & Liu, 2023)	Computer Vision, Motion-Based Methods, Appearance-Based Approaches, CNN	Automatización de sistemas de monitoreo de tráfico	video	objetos	X	X

(Host, Pobar, & Ivasic-Kos, 2023)	YOLOv2, SORT, Multilayer Perceptron (MLP), Bidirectional Long Short-Term Memory (BiLSTM), 3D Convolutional Neural Network	Detección automática de jugadores en el seguimiento de movimientos, y el reconocimiento de las acciones	video	personas	X	X
(Kim, Yoo, & Chung, 2023)	SlowFast Network Algorithm, YOLO y DeepSORT	Optimización de la extracción de datos de video en tiempo real para analizar el comportamiento humano	video	personas	X	X
(Gündüz & Işık, 2023)	YOLO v3, YOLO v4, YOLO v5s, YOLO v3-Tiny y YOLO v4-Tiny	Detección de personas para identificar áreas densas	video	personas	X	X

Fuente: elaboración propia

En la **Tabla 2-1** podemos concluir que todos los proyectos están bajo la rama del Deep Learning y la mayoría usa algoritmos de Redes Neuronales Convolucionales. Todos estos algoritmos son útiles a la hora de analizar video e imágenes para la detección de personas y objetos, lo cual los hace relevantes para el problema que se quiere trabajar.

De todos estos proyectos se encontró que el algoritmo YOLO es ampliamente usado tanto para imágenes como videos y ha empezado a ser tendencia desde el 2022 ya que ha demostrado tener un buen rendimiento y versatilidad para la detección de personas.

Ya que en la sección **2.1** analizamos el fenómeno de evasión y en la **Tabla 2-1** listamos proyectos similares donde se realizó algún tipo de análisis con personas u objetos, hemos definido que, para nuestro problema específico, nos centraremos en algoritmos que

permitan detectar personas, generar trayectorias únicas y detectar o clasificar acciones o poses. Esto con el fin de realizar un seguimiento de las personas que puedan ser posibles evasores y, mediante el análisis de sus acciones, determinar si se trata de un ingreso ilegal al sistema.

2.4.1 Algoritmos de Detección de Personas

Tabla 2-2 Ranking de algoritmos usados para detección de personas

Algoritmos	Proyectos de aplicación	Cantidad de proyectos	Descripción
YOLO (v2/v3/v4/v5, tiny)	(Gupta, et al., 2023) (Gündüz & Işık, 2023) (Host, Pobar, & Ivasic-Kos, 2023) (Kim, Yoo, & Chung, 2023) (Kumar & Bhatt, 2022) (Valarmathi, et al., 2023) (Wang, et al., 2021)	**7**	Detector de una sola etapa que predice directamente cajas y clases en celdas de grilla. Tiene variantes como “tiny" y nuevas versiones optimizan velocidad/precisión para personas y otros objetos.
SSD (incl. D-SSD)	(Gupta, et al., 2023) (Padhi, Sahoo, & Maity, 2021) (Valarmathi, et al., 2023) (Yang & Chen, 2019)	4	Detector de una sola etapa con “default boxes” en múltiples mapas de características. D-SSD añade deconvoluciones para mejorar objetos pequeños como peatones.
R-CNN-based (Faster R-CNN / R-FCN)	(Gupta, et al., 2023) (Valarmathi, et al., 2023)	2	Detectores de dos etapas con propuestas de regiones. Alta precisión para detección de personas.

Fuente: Elaboración propia

En la **Tabla 2-2** podemos ver que el algoritmo más utilizado para detección de personas es YOLO en múltiples versiones, presente en 7 proyectos, seguido por SSD (incl. D-SSD) con

4 apariciones y, en menor medida, por R-CNN-based (Faster R-CNN / R-FCN) con 2 apariciones. En conjunto, estos tres enfoques, todos basados en redes convolucionales profundas, concentran casi todos los casos de detección de personas, con YOLO destacando por su velocidad y balance entre precisión y eficiencia.

2.4.2 Algoritmos de Seguimiento de Objetos

Tabla 2-3 Ranking de algoritmos usados para seguimiento de objetos

Algoritmos	Proyectos de aplicación	Cantidad de proyectos	Descripción
Lucas-Kanade (LK)	(Hsiao & Tsai, 2018) (Ghaywate, Vyas, Telang, & Mangale, 2019)	**2**	Analiza el desplazamiento de puntos y característicos entre cuadros asumiendo constancia de intensidad;
DeepSORT	(Kim, Yoo, & Chung, 2023)	1	Extiende SORT con embeddings de apariencia aprendidos para re-identificación, mejorando así la asociación.
Horn–Schunck (HS)	(Hsiao & Tsai, 2018)	1	Flujo óptico denso y global. Útil para seguimiento basado en movimiento.
KCF (Kernelized Correlation Filter)	(Yang & Chen, 2019)	1	Rastreador mono-objeto que aprende un filtro de correlación en el dominio de Fourier (ridge regression). Muy rápido en tiempo real.
Kalman	(Yang & Chen, 2019)	1	Filtro de Kalman como estimador recursivo para trayectorias bajo dinámica lineal-gaussiana. Se usa para predicción y asociación entre detecciones.
Flujo óptico (genérico) (p. ej., FlowNet)	(Ghaywate, Vyas, Telang, & Mangale, 2019)	1	Familia de métodos que estiman el campo de movimiento, permiten propagar cajas/puntos y seguir objetos por consistencia temporal entre los cuadros.
SORT	(Host, Pobar, & Ivasic-Kos, 2023)	1	Framework de rastreo en tiempo real (online). Predice estados futuros con Kalman y asocia detecciones mediante IoU y algoritmo húngaro. Prioriza

			velocidad extrema y bajo coste computacional.

Fuente: Elaboración propia

En la **Tabla 2-3** se muestran los algoritmos usados para tracking de objetos, donde Lucas–Kanade es el método de flujo óptico más usado, seguido por DeepSORT, Horn–Schunck, KCF, Kalman, Flujo óptico genérico y SORT.

En conjunto, los proyectos muestran dos enfoques dominantes:

- Seguimiento basado en movimiento (Lucas–Kanade, Horn–Schunck, flujo óptico), que estima desplazamientos pixel a pixel.
- Tracking-by-detection (DeepSORT, SORT, KCF, Kalman), donde se combinan detecciones cuadro a cuadro con predicción y asociación temporal.

2.4.3 Algoritmos de Reconocimiento de Acciones Humanas.

Tabla 2-4 Ranking de algoritmos usados para detección de acciones/poses

Algoritmos	Proyectos de aplicación	Cantidad de proyectos	Descripción
CNN (Redes Neuronales Convolucionales)	(Ghaywate, Vyas, Telang, & Mangale, 2019) (Host, Pobar, & Ivasic-Kos, 2023) (Kim, Yoo, & Chung, 2023)	**3**	Redes neuronales ampliamente usadas para extracción automática de características espaciales en imágenes y videos. Sirve como base para la detección de poses y reconocimiento de acciones.
YOLO (You Only Look Once)	(Host, Pobar, & Ivasic-Kos, 2023) (Kim, Yoo, & Chung, 2023)	2	Detector de objetos en tiempo real que también se usa como base para detectar la posición y movimiento de personas en videos (modelo YOLO-pose).

BiLSTM (Bidirectional Long Short-Term Memory)	(Host, Pobar, & Ivasic-Kos, 2023)	1	Red neuronal recurrente que analiza secuencias temporales en ambas direcciones. Útil para identificar patrones dinámicos en las series de poses humanas o secuencias de acciones.
SlowFast Network	(Kim, Yoo, & Chung, 2023)	1	Arquitectura que procesa información a diferentes velocidades para capturar movimiento.
Red de Tripletes (Triplet Network)	(Nguyen, Pham, Ha, & Jeon, 2019)	1	Modelo de aprendizaje profundo que compara ejemplos para aprender similitudes; se usa para diferenciar patrones de movimiento o postura.
Optical Flow (Flujo Óptico)	(Ghaywate, Vyas, Telang, & Mangale, 2019)	1	Método clásico basado en el análisis de movimiento de píxeles entre cuadros consecutivos. Se usa para inferir dirección y magnitud de acciones humanas.
TW-RPCA (Truncated Weighted Robust PCA)	(Li, 2022)	1	Técnica estadística robusta usada para separar movimiento (acción) del fondo. Permite extraer regiones dinámicas útiles para análisis de comportamiento y detección de acciones.

Fuente: Elaboración propia

En la **Tabla 2-4** se observa que, de los 20 proyectos analizados, 5 abordan explícitamente la detección de acciones humanas o poses.

Los algoritmos más frecuentes son las CNN (3 proyectos) y YOLO (2 proyectos), que constituyen el núcleo moderno de las arquitecturas para human action recognition y pose estimation. Las otras variantes combinan el análisis espacial y temporal para mejorar la precisión en secuencias de video.

3. Trabajos Relacionados

Debido a que la forma de evasión por vagones de sistemas BRT no es tan común, hay pocos trabajos que implementen el análisis de video para detectar evasión en el sistema en América Latina, sin embargo, en el trabajo "Sistema de tratamiento de imágenes con tecnologías IoT para el control y monitoreo: Caso de estudio evasión por puerta de vagón en las estaciones de TransMilenio" (Burgos, Velásquez, & Rosero, 2018), se presenta una propuesta de caso de estudio para abordar la evasión por puertas de vagones en las estaciones de TransMilenio. Los autores proponen un prototipo de sistema que utiliza tecnologías IoT y sistemas embebidos para solucionar este problema. En este artículo también se analizan tecnologías relacionadas con el procesamiento de imágenes y su aplicación en este proyecto, entre las cuales se destacan:

- OpenCV: Esta biblioteca es ampliamente utilizada en visión por computadora y procesamiento de imágenes. Se emplea para una variedad de tareas, incluida la detección de objetos y características en imágenes.
- Algoritmo de Canny: Este algoritmo es útil para detectar bordes en imágenes y segmentarlas. Funciona mediante convolución y la primera derivada de la imagen, lo que facilita la identificación de límites y contornos.
- Algoritmo Minimum Bounding Box: Se utiliza para identificar el contenedor geométrico de área mínima alrededor de un objeto, lo que resulta beneficioso como filtro en la detección de personas.
- Algoritmo Haar Cascade: Este enfoque se basa en el aprendizaje automático y requiere entrenamiento previo con imágenes que contienen y no contienen el objeto

buscado. Es especialmente útil para la detección de patrones específicos en imágenes.

- Algoritmo K-Nearest Neighbors (KNN): Este algoritmo se emplea para extraer el fondo de una imagen y resaltar el objeto en movimiento. Esto facilita un análisis posterior de los elementos en movimiento en la escena.

Estos algoritmos desempeñan un papel crucial en el sistema de tratamiento de imágenes con tecnologías IoT desarrollado en el estudio, permitiendo la detección y seguimiento de personas en las estaciones de TransMilenio con el objetivo de prevenir la evasión de pago.

Por otro lado, en El trabajo "Detección y conteo de evasores en el sistema de transporte TransMilenio" (Rodríguez Peraza, 2024) propone una solución basada en visión por computadora y aprendizaje automático para identificar y cuantificar a los usuarios que evaden el pago en los torniquetes del sistema TransMilenio de Bogotá. El estudio parte del problema financiero y operativo que representa la evasión, así como de la falta de herramientas automáticas para medirla con precisión. Se recopilaron videos reales de las estaciones, los cuales fueron limpiados, segmentados y etiquetados de forma semiautomática para crear un conjunto de datos adecuado al entrenamiento de modelos.

Inicialmente se probaron métodos de detección de anomalías (GAN, autoencoders, MemAE, etc.), pero debido a la complejidad del entorno y la escasez de etiquetas, el enfoque se orientó hacia un modelo denominado PAWS3D, una adaptación de la metodología *PAWS (Predicted Alignment With Support)* al dominio del video. Este modelo combina técnicas de aprendizaje semi-supervisado y representaciones tridimensionales espaciotemporales, lo que permite distinguir entre acciones de pago legítimo y evasión mediante el análisis de movimiento en secuencias cortas de video.

Este trabajo es uno de los más recientes y directamente relacionados con el problema de la evasión en TransMilenio. Sin embargo, su enfoque se centra específicamente en los

torniquetes de acceso, por lo que aborda el mismo fenómeno desde una perspectiva diferente, tanto en la naturaleza de los datos utilizados como en la forma de analizar el comportamiento evasor. Mientras otros estudios se orientan hacia la estimación estadística o el análisis sociocultural del problema, este trabajo adopta un enfoque técnico basado en visión por computadora y aprendizaje automático, proponiendo un sistema automatizado para detectar y cuantificar a los evasores a partir del análisis de video.

Por el lado de TransMilenio, desde el año 2021 ha venido trabajando en el Sistema Inteligente de Detección de Eventos de Seguridad en TransMilenio (SIDEST), el cuál es un sistema basado en inteligencia artificial (IA) implementado por TransMilenio S.A. para monitorear, registrar la evasión y mejorar la seguridad en el componente troncal de TransMilenio. Este sistema utiliza cámaras y software de IA para detectar y clasificar usuarios del sistema que ingresan y salen de las estaciones o portales en dos categorías: "persona que evade el pago" y "persona que valida su pasaje" (TransMilenio S.A., 2023a).

El SIDEST se ejecuta en la nube de Google Cloud Platform (GCP) y consta de cuatro módulos: gestión de usuarios, configuración del sistema, evasión y seguridad. El módulo de evasión contiene dos algoritmos para detectar y clasificar eventos de evasión en torniquetes y puertas laterales. Para el fenómeno de evasión en las puertas de los vagones, El algoritmo detecta personas desde una vista oblicua utilizando una red neuronal de la familia EfficientDet y clasifica los eventos de evasión en dos categorías: ingreso normal y evasión por puerta lateral, basándose en un análisis de las áreas entre los recuadros delimitadores de las personas detectadas (TransMilenio S.A., 2023b).

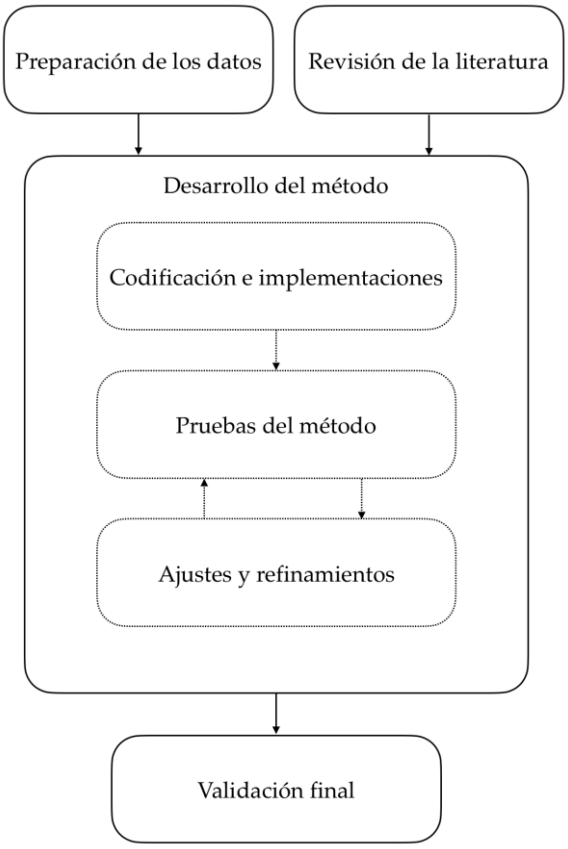
4. Metodología

Para desarrollar este proyecto y cumplir con los objetivos planteados, se trabajó en seis fases:

- **Revisión de la literatura**: En la sección **2.4** se realizó una revisión de la literatura existente sobre técnicas de inteligencia artificial aplicables a la detección de evasión en sistemas de transporte público, en el capítulo de **Trabajos Relacionados** se tuvo en cuenta estudios de caso similares y en la información proporcionada por TransMilenio. Además, se elaboró un ranking de métodos útiles para la detección de personas u objetos, el seguimiento de personas (tracking), y el reconocimiento de poses o acciones, los cuales se usaron como base para desarrollar el método.
- **Preparación de los datos**: En esta etapa, se seleccionó un conjunto de videos representativos de la evasión en puertas de vagones, provenientes del sistema de cámaras de TransMilenio. Posteriormente, se estandarizaron los metadatos para facilitar su procesamiento. En la sección **4.1** se habla del origen de estos datos.
- **Desarrollo del método**: Se realizó la codificación, implementación de algoritmos y configuración de parámetros asociados al diseño y desarrollo del método, basándose en los hallazgos de la revisión de la literatura y en los experimentos realizados a lo largo de las implementaciones.
- **Pruebas del método:** Tras obtener la primera versión, se emplearon los datos disponibles para realizar una búsqueda de cuadrícula (grid search). Esto permitió evaluar el desempeño en la detección de evasión por puertas de vagón y determinar la configuración de parámetros más efectiva.

- **Ajustes y refinamientos**: En esta fase se revisaron los resultados de las pruebas y se realizaron ajustes y refinamientos en el método para mejorar su rendimiento.
- **Validación final**: Una vez realizados los ajustes finales al método, se llevó a cabo una validación final para asegurar que cumpliera con los objetivos propuestos.

Figura 4-1 Metodología



Fuente: elaboración propia

En la **Figura 4-1** se pueden observar las fases del método de estudio y su ejecución. Dentro de todo el proyecto, la revisión de la literatura y la preparación de los datos son las únicas fases que se pueden ejecutar simultáneamente. Las fases de pruebas del método, ajustes y refinamientos son incrementales, ya que se pueden necesitar varias iteraciones para mejorar el método.

4.1 Dataset

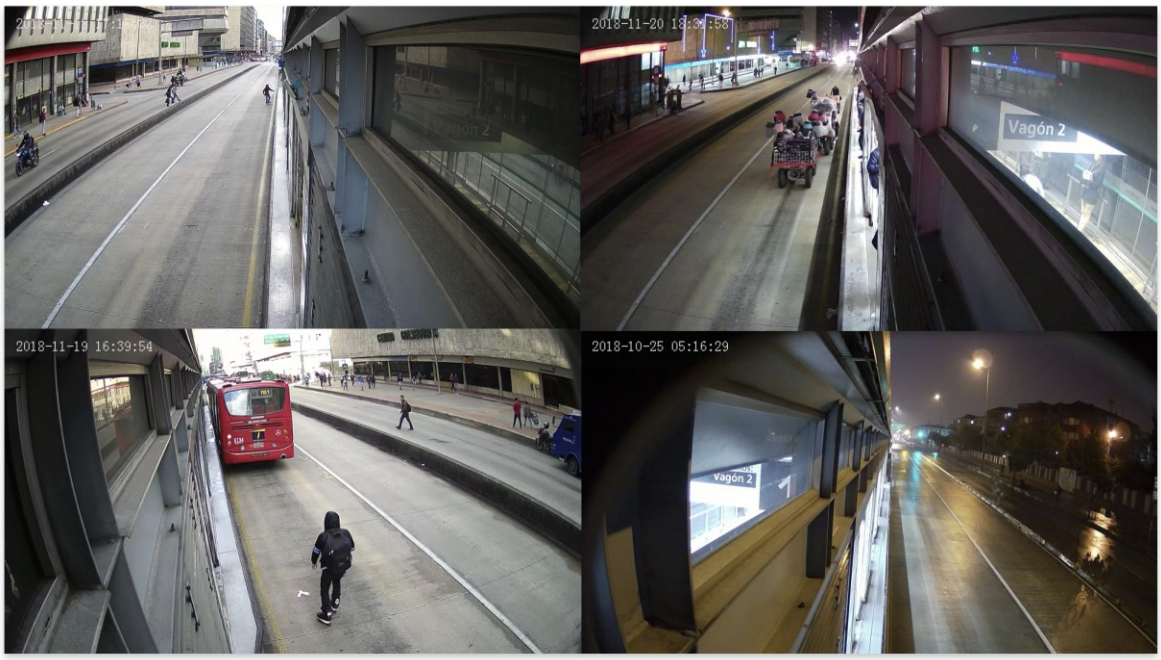
En 2018, TransMilenio S.A. contrató a la Universidad Nacional de Colombia (UNAL) para desarrollar el estudio de línea base de evasión en el componente troncal del sistema, con el propósito de establecer una metodología científica y representativa que permitiera medir de forma precisa la cantidad de usuarios que ingresan sin pagar el pasaje. La investigación realizada por la Universidad Nacional definió la metodología oficial que TransMilenio ha continuado utilizando en los estudios de evasión posteriores 2021-II, 2022-I, 2022-II y 2024-I) (TransMilenio S.A, 2023b; TransMilenio S.A, 2024).

Uno de los componentes más relevantes de este trabajo fue la recolección de datos mediante grabaciones de video, a través de una estrategia operacional que consistió en instalar cámaras para capturar la totalidad de los torniquetes y accesos laterales de las estaciones seleccionadas, con el fin de contabilizar tanto los ingresos validados (con pago) como los no validados (evasión).

Gracias a este despliegue técnico se obtuvieron 48.300 horas de grabación, de las cuales 13.800 horas fueron digitalizadas y analizadas manualmente por el equipo de la Universidad, constituyendo la fuente primaria de datos para determinar el número de ingresos válidos y evasores en cada punto de observación (TransMilenio S.A., 2023a).

4.1.1 Características de los Videos

Figura 4-2 Ejemplos de grabaciones en puertas de vagón



Fuente: elaboración propia

Como se puede ver en la **Figura 4-2**, presenta escenas captadas en estaciones del sistema de transporte TransMilenio. Las cámaras están ubicadas en la parte superior lateral de los vagones, apuntando hacia el corredor exclusivo de los buses troncales. Estas grabaciones fueron tomadas desde las 4 a.m. hasta las 12 a.m., en las cuales hay escenas diurnas y nocturnas. En la sección **2.1** se habló de los comportamientos de las personas al entrar ilegalmente por las puertas de los vagones y las consideraciones para tener en cuenta al analizar estos videos y comportamientos. Sin embargo, también es importante recalcar que es necesario detectar la estación y su ubicación para determinar entradas ilegales, ya que esta puede cambiar según la ubicación de la cámara.

4.2 Preparación de los Datos

En este trabajo se utilizaron los videos mencionados en la sección **4.1** que fueron recolectados por la Universidad Nacional en 2018. A partir de ellos, se recortaron clips entre 20 y 24 segundos que presentaban casos de evasión, con lo cual se generó un dataset de 1.800 videos: 1.200 con casos de evasión y 600 sin ellos. Cada video cuenta con metadatos asociados, que proporcionan información útil para el entrenamiento y la validación del método desarrollado.

La creación de este dataset se realizó antes de iniciar el desarrollo del método, por lo que se extrajeron diversas características que ofrecían mayor contexto y podían resultar útiles durante las etapas de prueba y evaluación de este.

Tabla 4-1 Metadatos de los clips que conforman el dataset

Atributo	Tipo de dato	Valores	Significado
nombre	texto	---	Nombre del video.
evasión	booleano	0 / 1	Indica si en el video se presenta un caso de evasión (1) o no (0).
categoría	texto	CASO_1 CASO_2 CASO_3 CASO_4	En los videos clasificados como evasión, se identificaron tres tipos de casos. • En el CASO_1, la persona atraviesa la calle, salta hacia la estación y entra por la puerta lateral. • En el CASO_2, la persona aparece desde el lado de la estación y accede por la puerta lateral. • En el CASO_3, la persona aprovecha el momento en que el bus está abordando, llega desde la calle, se sube a la estación, camina por fuera e ingresa junto con las personas que ya se encontraban allí.

			Por otro lado, en los videos clasificados como no evasión se identificaron cuatro tipos de comportamientos. • En el CASO_1, la persona ya se encuentra dentro de la estación y aborda el bus. • En el CASO_2, la persona sale de la estación por la puerta hacia la calle. • En el CASO_3, la persona, estando en la estación, se asoma hacia afuera y luego regresa. • En el CASO_4, la persona se desplaza por el carril de TransMilenio, pero no ingresa a la estación (por ejemplo, peatones o personal operativo).
cantidad	número	0 - n	Número de entradas ilegales presentes en el video.
complejo	booleano	0 / 1	Indica si el clip presenta comportamientos complejos que dificultan determinar si una entrada es válida o no.
duración	número	20 - 24	Duración del clip en segundos.
orientación	texto	BACK FRONT	Indica la orientación desde la cual aparece el bus; también determina el lado de la estación visible en el video.
estación	texto	---	Nombre de la estación de donde se extrajo el clip.
fecha	fecha	---	Fecha y hora del clip, útil en caso de requerir preprocesamiento específico (por ejemplo, para videos nocturnos).

Fuente: elaboración propia

4.3 Modelos y Técnicas Implementadas

Partiendo del análisis realizado en la sección **2.1 Evasión** y los atributos de los clips en la **Figura 4-3**, el primer paso en el desarrollo del método consiste en detectar la estación y su ubicación, con el fin de delimitar las zonas de interés que resultan relevantes para el análisis de la evasión en cada video.

4.3.1 Detección de la Estación

Ya que en la revisión de la literatura se encontró que YOLO puede ser implementado en múltiples tareas de visión computacional, se decidió usarlo para segmentar la estación y encontrar el polígono que defina la forma y ubicación de esta. Esta es una tarea avanzada de visión artificial que permite generar contornos o polígonos para una clase determinada como se puede ver en la **Figura 4-3**. YOLO ofrece modelos pre-entrenados con el dataset COCO, brindando la posibilidad de adaptarlo a un dataset con clases especificas (Ultralytics Inc., 2025a).

Figura 4-3 Ejemplos de segmentación de instancias



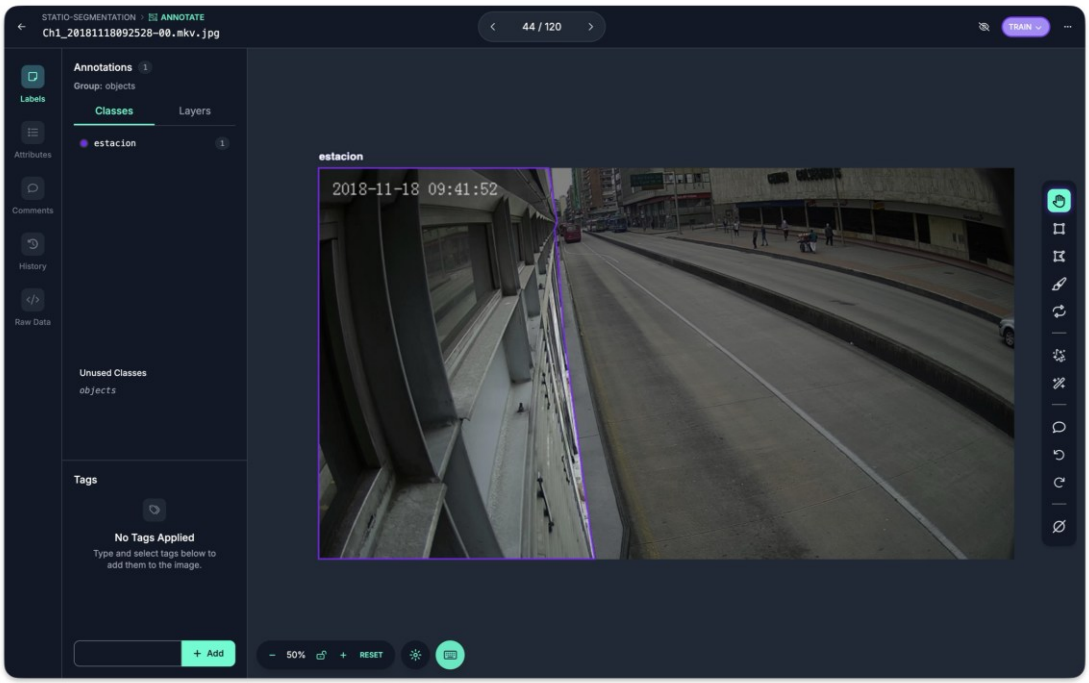
Fuente: Instance segmentation, por Ultralytics Inc. (2025), Ultralytics Docs (https://docs.ultralytics.com/es/tasks/segment/).

Teniendo en cuenta que las estaciones no cambian de forma y presentan características similares, se extrajo un dataset de 120 imágenes, correspondientes al primer frame de clips

seleccionados aleatoriamente. Se utilizó la herramienta Roboflow para delimitar el polígono de la estación y asignar etiquetas a dichas imágenes en el formato aceptado por YOLO (Ultralytics, 2025b). Esto se realizó con el propósito de reentrenar el modelo y permitir la predicción automática del polígono de la estación.

Como se explicó en la Sección **2.1**, correspondiente al fenómeno de evasión, en el caso 2 las personas pueden aparecer debajo de la cámara. Si el polígono de la estación incluye la plataforma utilizada para abordar el bus, podría generar falsos positivos, considerando que la persona ya se encuentra dentro de la estación de forma legal. Por esta razón, se generaron dos datasets para segmentar la estación: uno considerando el polígono completo y otro excluyendo la plataforma, como se muestra en la **Figura 4-4**.

Figura 4-4 Ejemplo de etiquetado de estaciones con Roboflow

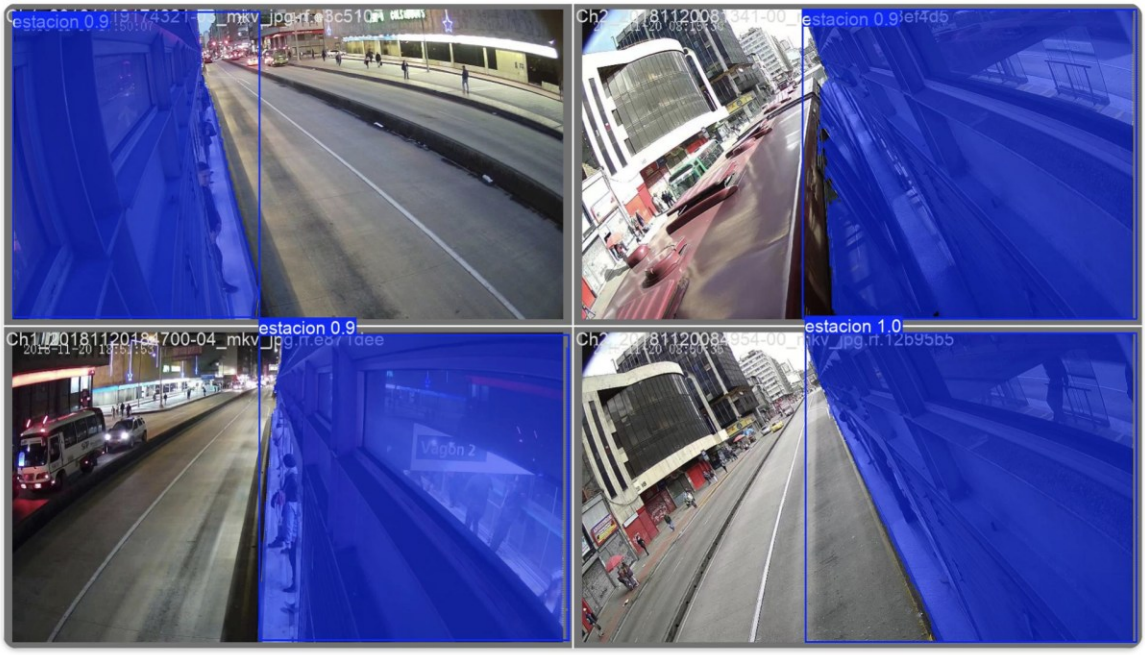


Fuente: Elaboración propia

Después de generar estos dos datasets, se entrenaron modelos de YOLO, específicamente YOLO11s-seg y se obtuvieron dos modelos capaces de segmentar la estación como se puede ver en las figuras **Figura 4-5** y **Figura 4-6**.

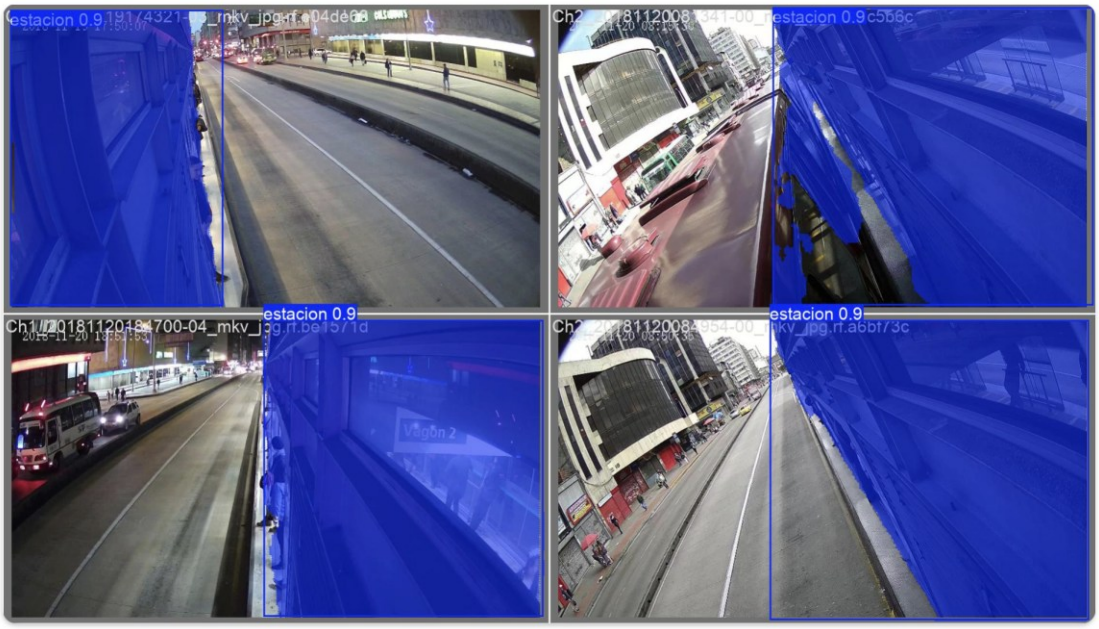
Estos modelos funcionaron correctamente en la gran mayoría de los casos; sin embargo, en algunas ocasiones se observó que el primer fotograma presentaba escenas con la llegada de buses o una alta concentración de personas, ejemplos presentados en la **Figura 4-5** y **Figura 4-6**. Esto ocasionaba que el método generara un polígono menos ajustado a la estación. Para mitigar este problema, durante el desarrollo del método se implementó un proceso en el que, al analizar un video, se comparan los polígonos predichos en varios fotogramas. La relación entre el perímetro y el área se utiliza como criterio de selección: a menor valor, mayor es el ajuste del polígono. Este valor determina cuál de los dos polígonos se utiliza finalmente para representar la estación.

Figura 4-5 Ejemplos de predicción para estación completa



Fuente: Elaboración propia

Figura 4-6 Ejemplos de predicción para estación sin plataforma



Fuente: Elaboración propia

4.3.2 Detección de Personas

En la sección **2.4.1** se analizaron diferentes algoritmos utilizados para la detección de personas, entre los cuales YOLO destacó por su versatilidad en diversas aplicaciones y por los buenos resultados que ofrece. Para realizar la detección, es necesario identificar las regiones de los fotogramas donde se encuentran las personas; en este proceso, YOLO genera bounding boxes con un nivel de confianza y una etiqueta asignada (Ultralytics Inc., 2025c). En este trabajo, solo se tuvo en cuenta la etiqueta 0, correspondiente a la clase "persona".

Figura 4-7 Ejemplos de segmentación de instancias

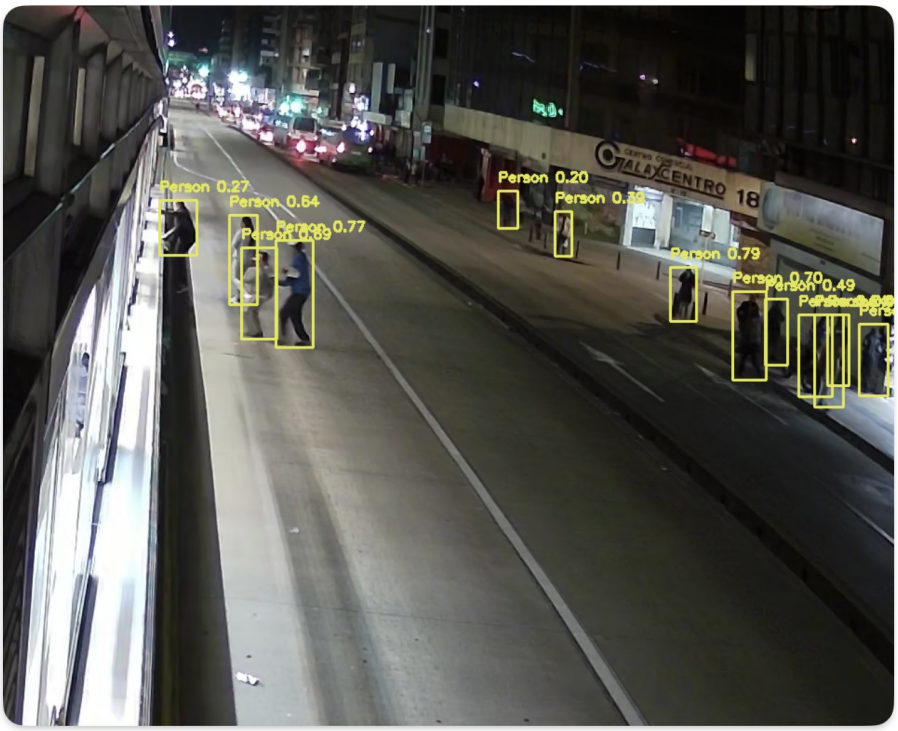


Fuente: Object detection, por Ultralytics Inc. (2025), Ultralytics Docs

(https://docs.ultralytics.com/es/tasks/detect/).

YOLO posee diferentes versiones para su modelo de detección en las cuales todas son pre-entrenadas con el dataset COCO y la diferencia entre estas es la cantidad de parámetros que puede trabajar, para este trabajo se hicieron diferentes experimentos con los modelos desde la versión más pequeña hasta la más grande, en la **Figura 4-8** podemos observar un ejemplo de implementación con la versión s(small) de YOLO. En todos los modelos se logró detectar personas; sin embargo, en algunos casos, cuando los usuarios ingresan desde la calle a la estación realizando poses atípicas, el modelo deja de detectarlos. Este aspecto se abordará más adelante en los refinamientos del método desarrollado.

Figura 4-8 Ejemplo de implementación de YOLO al contexto específico



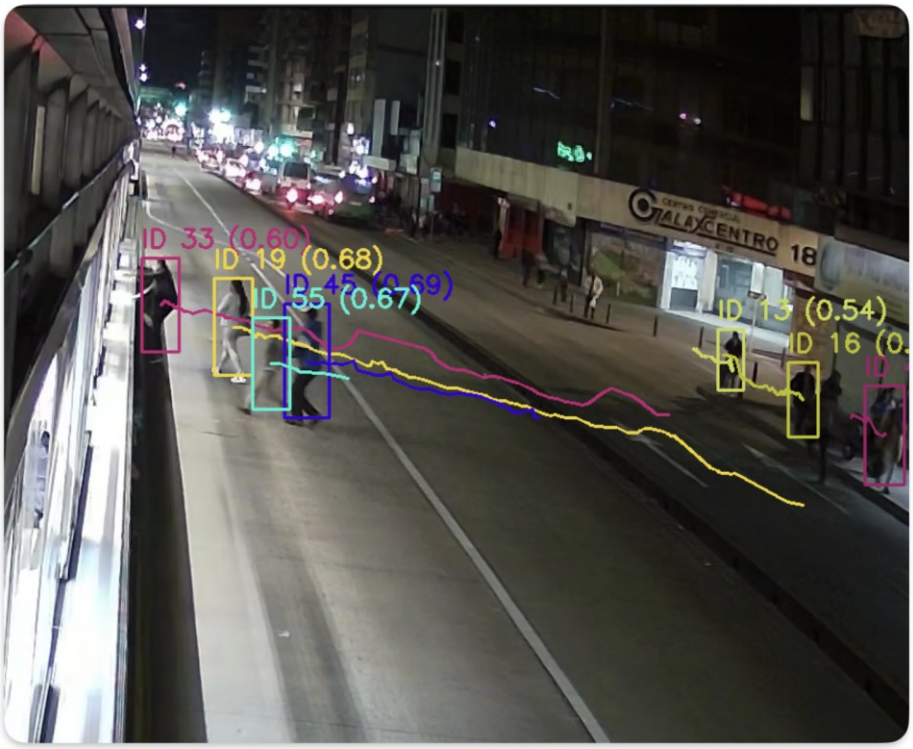
Fuente: Elaboración propia

4.3.3 Tracking de Personas

Para este proyecto es fundamental no solo identificar a las personas en los videos, sino también poder hacerles seguimiento durante toda la escena. En la revisión de la literatura se encontraron varios algoritmos utilizados para el tracking de objetos; sin embargo, dado que la detección de personas se realizó con YOLO, este modelo ya incorpora un módulo de seguimiento que facilita este proceso. La salida generada por los trackers es consistente con la detección estándar de objetos, pero añade un valor clave: la asignación de IDs únicos. Esto permite rastrear a cada persona a lo largo del video y realizar análisis posteriores como se puede observar en la **Figura 4-9**.

YOLO resulta especialmente útil para el seguimiento de objetos, ya que permite procesar secuencias de video en tiempo real sin comprometer la precisión, soporta múltiples algoritmos y configuraciones de tracking, y además puede emplearse con modelos YOLO entrenados a la medida, lo que permite adaptarlo fácilmente a aplicaciones específicas del dominio (Ultralytics Inc., 2025d).

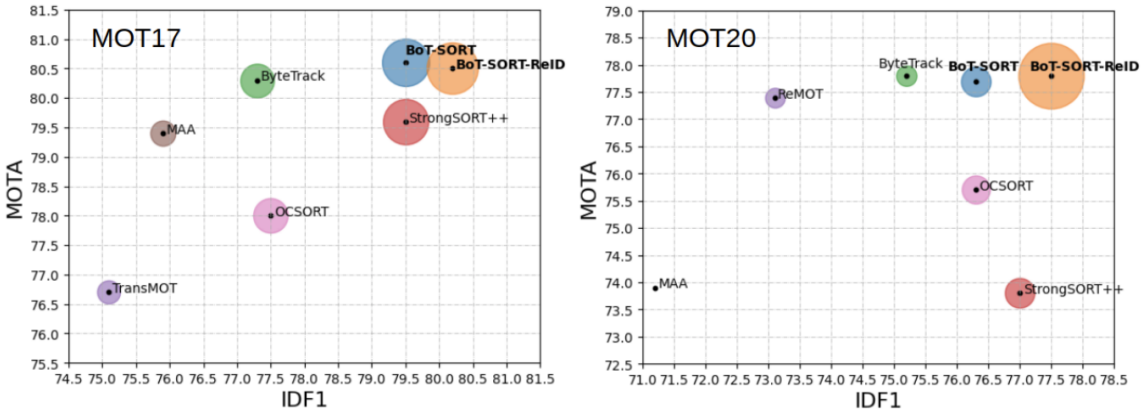
Figura 4-9 Ejemplo de implementación de tracker al contexto específico



Fuente: Elaboración propia

Actualmente YOLO tiene implementados dos de los mejores trackers: ByteTrack y BoT-SORT. En la **Figura 4-10** se presenta una comparación del desempeño de varios trackers, evaluando qué tan bien mantienen las identidades, su precisión y el equilibrio entre la detección y la asociación (representado por el tamaño del círculo).

Figura 4-10 Comparación de desempeño de trackers en dataset MOT27 y MOT20



Fuente: **BoT-SORT: Robust Associations Multi-Pedestrian Tracking**

por N. Aharon et al., 2022, arXiv (https://arxiv.org/abs/2206.14651).

Para este proyecto se implementaron ambos trackers, pero más adelante en la sección **4.5**, referente a la exploración de parámetros, se determina cuál de los dos es más robusto para el contexto especifico de los casos que se presentan en los videos. Ya que YOLO tiene una configuración genérica para estos trackers y en los videos de evasión hay varios factores para tener en cuenta, a continuación, se presenta la **Tabla 4-2** con las configuraciones usadas para la implementación de los trackers.

Tabla 4-2 Parámetros usados para la configuración de los trackers

Categoría	Parámetro	Descripción	ByteTrack	BoT-SORT
tracker	tracker_type	Método de seguimiento	bytetrack	botsort
Modelo de ReID	with_reid	Habilita la re-identificación para mantener mejor las identidades.	True	True

	reid_model	Modelo utilizado para comparar apariencia entre cuadros.	osnet_x0_25_msmt17.pt	osnet_x0_25_msmt17.pt
	model	Autocarga del modelo de ReID compatible.	auto	auto
	fast_reid_config	Configuración avanzada del módulo ReID.	—	Archivo de configuración Bagtricks R50
	fast_reid_weights	Pesos del modelo ReID avanzado.	—	osnet_x0_25_msmt17.pt
Umbrales de detección	track_high_thresh	Confianza mínima para mantener un track activo.	0.4	0.45
	track_low_thresh	Umbral mínimo para considerar detecciones débiles temporalmente.	0.05	0.1
	new_track_thresh	Confianza mínima para iniciar un nuevo track.	0.5	0.55
Asociación	match_thresh	Umbral global de similitud para decidir si dos detecciones pertenecen al mismo objeto.	0.8	0.8
	proximity_thresh	Umbral de distancia espacial; más alto = más permisivo.	0.6	0.6
	appearance_thresh	Peso de la similitud visual basada en ReID.	0.25	0.3
Persistencia	track_buffer	Número de cuadros durante los que se mantiene un ID antes de descartarlo.	180	180
	max_time_lost	Tiempo máximo antes de dar por perdido un objeto.	180	180
Corrección movimiento	gmc_method	Método para compensar	sparseOptFlow	sparseOptFlow

		movimiento de cámara u objetos.		
Otros parámetros	fuse_score	Fusiona score del detector y la apariencia.	True	True
	enable_camera_motion_compensation	Activa compensación de movimiento de cámara.	—	True
Parámetros avanzados	max_reid_distance	Distancia máxima para considerar que dos apariencias son iguales.	—	0.4
	min_box_area	Descarta detecciones demasiado pequeñas.	—	10

Fuente: Elaboración propia

4.3.4 Detección de Acciones

Una vez que las personas fueron identificadas y sus trayectorias se mantuvieron a lo largo de varios fotogramas, fue posible comenzar a desarrollar la lógica necesaria para determinar cuándo una trayectoria corresponde a una entrada ilegal al sistema. Inicialmente, se consideró analizar las poses que realizaban las personas a medida que avanzaba la escena; sin embargo, dos aspectos importantes llevaron a concluir que lo más adecuado era enfocarse en las interacciones de las trayectorias con el polígono de la estación.

Para analizar las poses de personas es necesario contar con keypoints del cuerpo. En un primer intento se implementó YOLO Pose, que además buscaba refinar la detección en casos donde los usuarios adoptaban poses atípicas que podían causar la pérdida de la detección. No obstante, YOLO Pose trabaja con 17 keypoints y requiere que la persona tenga una resolución mínima en la imagen para poder identificarlos (Ultralytics Inc.,

2025e). En los videos de evasión utilizados en este proyecto es común que aparezcan personas a la distancia, ocupando pocos píxeles en la escena, lo que impide que el modelo detecte correctamente sus keypoints, como se puede observar en la **Figura 4-11** la persona deja de ser detectada cuando su tamaño disminuye.

Durante los experimentos realizados para intentar integrar YOLO Pose, se intentó aumentar considerablemente la resolución de entrada del modelo, pero esto no logró solucionar el problema de detección para las acciones más relevantes en la trayectoria. Además, el incremento en resolución redujo significativamente el rendimiento del método ya que el costo computacional era demasiado alto, por lo que esta aproximación fue descartada.

Figura 4-11 Pérdida de objetos pequeños en implementación de YOLO-pose



Fuente: Elaboración propia

4.3.5 Análisis de Trayectorias

Por las razones expuestas anteriormente, se decidió trabajar únicamente con el modelo estándar de YOLO para la detección de personas. A partir de estas detecciones se adoptó un enfoque basado en reglas aplicadas sobre las trayectorias para determinar si correspondían a casos de evasión.

En la tabla **Tabla 4-3** se especifican las reglas aplicadas a las trayectorias para determinar cuándo se considera como una entrada ilegal, estas reglas se aplican principalmente en dos casos observados con las trayectorias:

- Caso 1: El track se mantiene durante toda la escena, empieza fuera de la estación e ingresa en el polígono.
- Caso 2: El track se pierde, pero desaparece cerca del polígono y su dirección es orientada hacia la estación.

Tabla 4-3 Reglas aplicadas a las trayectorias para la detección de evasión

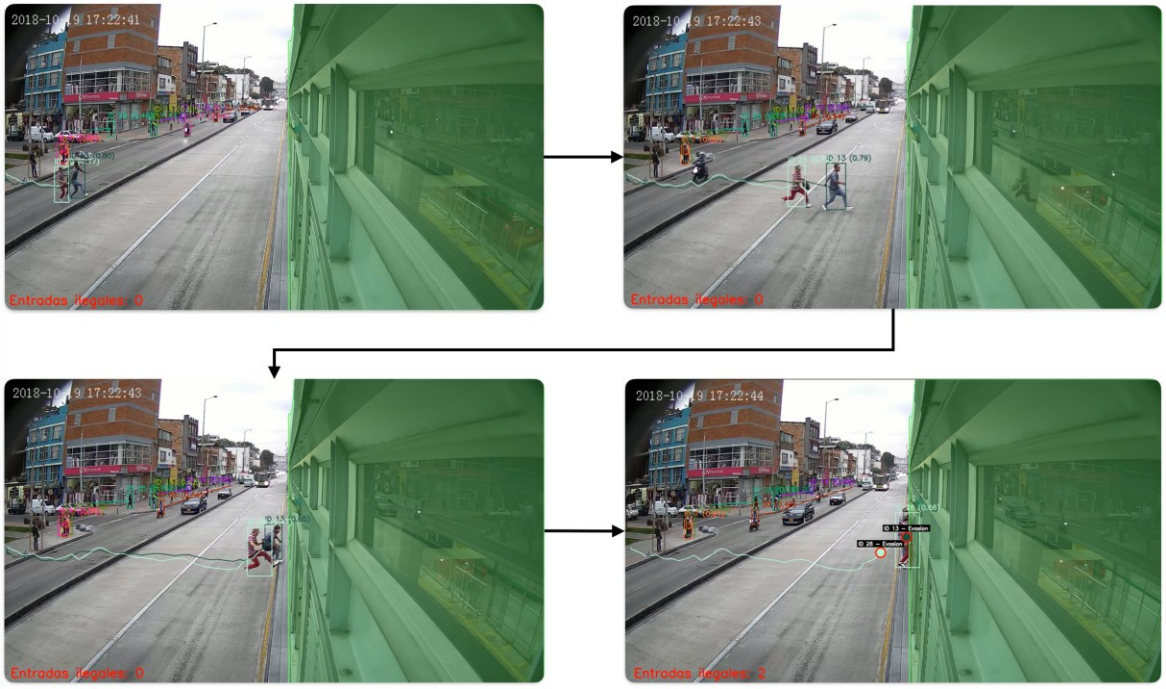
Tipo de regla	Criterio	Acción resultante	Caso afectado
Descartar track	El track aparece por primera vez dentro del polígono de la estación	El track se ignora completamente	—
Requisito temporal mínimo fuera	Tiempo desde primera detección del track ≥ MIN_TIME_OUTSIDE segundos (por defecto 1 s)	Permite considerar el track como candidato a evasión y evitar confusión con tracks de personas que entran de los buses a la estación	Caso 1 y Caso 2
Caso 1: Entrada directa al polígono	Track pasa de estar fuera → dentro del polígono + tiempo mínimo	Se marca inmediatamente como evasión ya que la persona estuvo fuera suficiente tiempo y luego entró a la zona controlada	Caso 1
Caso 2: Desaparición cerca del polígono	Track desaparece (no está en frame actual) y cumple todas las subreglas 1 a la 4	Se marca como evasión, este caso intenta capturar a quien	Caso 2

		salta o ingresa sin que el tracker lo vea entrar	
Subregla 1 para el caso 2	Cumplir con el requisito temporal de vide del track	Se usa el mismo parámetro de MIN_TIME_OUTSIDE	
Subregla 2 para el caso 2	Distancia del último punto visto al borde del polígono ≤ PROXIMITY_THRESHOLD	Solo cuenta desapariciones cerca de la estación	
Subregla 3 para el caso 2	La trayectoria tiene un mínimo de puntos	Para poder analizar dirección	
Subregla 4 para el caso 2	Las distancias de los últimos 3 puntos al polígono son decrecientes (se acerca progresivamente a la estación)	Confirma intención de acercarse a la estación	
Evitar doble conteo	Track ya fue marcado como evasión en cualquiera de los dos casos	Evita que un mismo ID nunca genera más de una evasión	Caso 1 y Caso 2

Fuente: Elaboración propia

Una vez se aplicaron estas reglas al método, en conjunto con la detección de la estación, las personas y sus trayectorias, se logró extraer conteos de evasión sobre los clips. En la **Figura 4-12** se pueden ver fotogramas de un video procesado donde se observan las personas, las trayectorias, y el momento donde se determina qué es evasión. En este caso podemos ver que se aplican ambas reglas de la **Tabla 4-3** ya que el track 13 no se perdió y se pudo detectar con el caso 1, y el track 28 desapareció cerca de la estación, pero por su trayectoria es considerado como evasión.

Figura 4-12 Detectando evasión aplicando el método desarrollado



Fuente: Elaboración propia

4.4 Refinamiento

Durante todo el desarrollo de este método, se hicieron varios experimentos para codificar e ir mejorando la capacidad de este en cada tarea de visión artificial, pero en la sección **4.3.2** se habló sobre las posibles mejoras en la detección de personas para mejorar el desempeño general del método.

El WiderPerson es un dataset diseñado para la detección de personas en escenarios reales altamente concurridos. Contiene 13.382 imágenes recolectadas desde múltiples fuentes y contextos, con 39.9786 anotaciones, lo que lo convierte en uno de los conjuntos más densos y diversos para este tipo de tarea. Las imágenes incluyen grandes variaciones en iluminación, ángulos, fondos, escalas y nivel de oclusión, e incorporan cinco tipos de

anotaciones: peatones, riders, personas parcialmente visibles, multitudes y regiones a ignorar. Esta riqueza de escenarios y la alta cantidad de personas por imagen (en promedio casi 29 por foto) lo hace especialmente útil para entrenar modelos robustos (Zhang S. X., 2019).

En el caso específico de TransMilenio, este dataset resulta útil ya que presenta casos similares a los que ocurren en escenas de evasión. Por un lado, tiene muchos casos donde se agrupan personas, y por el otro, también presenta casos con poses atípicas, ya que en este dataset hay muchas imágenes donde las personas practican algún deporte, en la **Figura 4-13**, podemos ver la diversidad de casos en este dataset.

Tras la construcción del dataset, se entrenó un modelo YOLOm, generando un archivo de pesos listo para ser integrado en el método. Durante la implementación se observó que, en algunos casos, este modelo mejoraba la detección de personas; sin embargo, en pruebas manuales su rendimiento fue similar al de YOLO11m, por lo que su uso no resultó determinante para la implementación final. Aun así, en la etapa de exploración de parámetros se evaluaron combinaciones que incluyeron tanto este modelo como varias versiones de YOLO base, con el fin de establecer cuál ofrecía el mejor desempeño para el proyecto, ya que los resultados variaban según el escenario: en algunos casos YOLO base fue superior, mientras que en otros el modelo YOLOm logró mejores detecciones.

Figura 4-13 Escenarios presentados en el dataset WiderPerson



Fuente: **WiderPerson: A diverse dataset for dense pedestrian detection in the wild** por S. Zhang, Y. Xie, J. Wan, H. Xia, S. Z. Li y G. Guo, 2019, arXiv (`https://arxiv.org/abs/1909.12118).

4.5 Exploración de Parámetros

Una vez que se tuvo el método base, se exploraron diferentes parámetros para encontrar los mejores aplicados al contexto específico, para esto se realizó un muestre de 300 videos seleccionados aleatoriamente, donde 100 eran de clips donde no se presentaba evasión y 200 donde sí. A continuación, se presentan los parámetros explorados para crear 40 diferentes configuraciones, analizar el rendimiento de cada una y determinar la mejor para aplicarla en la validación final.

Tabla 4-4 Parámetros explorados con grid search

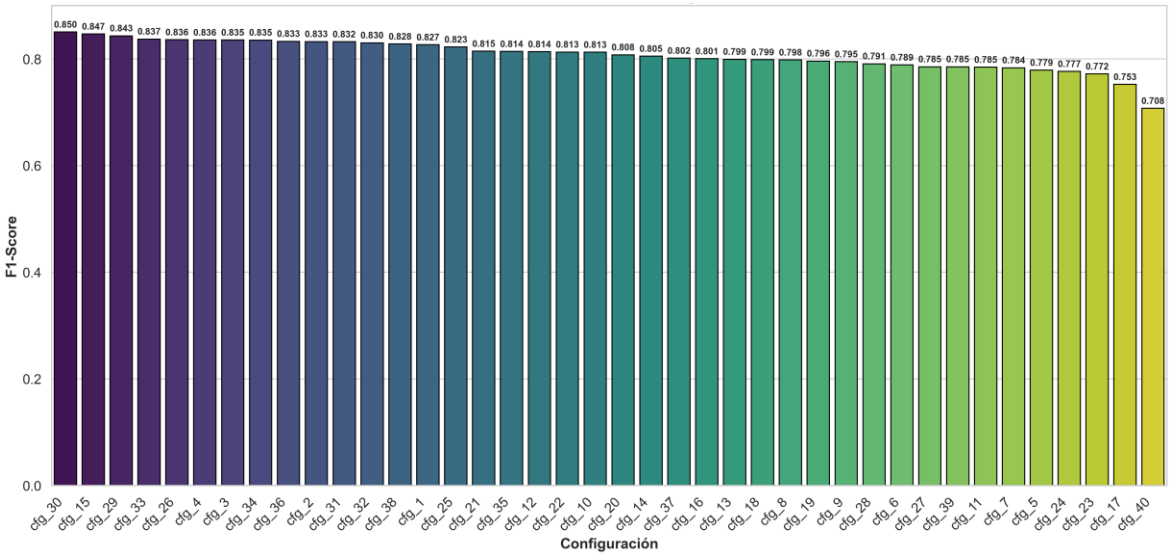
Parámetro	**Valores evaluados**	**Descripción**
person_model	• yolo11s • yolo11m • yolo11tm	Modelo YOLO utilizado para detección de personas. Las variantes *s* (small) y *m* (medium) son modelos base; yolo11tm es el modelo entrenado con el dataset de WiderPerson **Figura 4-13**.
station_model	• stationv1 • stationv2	Modelo YOLO encargado de detectar el polígono de la estación. La versión v1 toma en cuenta toda la estación y la v2 toma la estación sin la plataforma **Figura 4-5** y **Figura 4-6**
person_conf	• 0.35 • 0.40 • 0.50	Nivel mínimo de confianza requerido para aceptar una detección de persona. Valores más altos reducen falsos positivos, pero podrían perder detecciones lejanas o parciales.
person_iou	• 0.4 • 0.5	Umbral IoU para el proceso de *Non-Maximum Suppression*. Controla qué tan estricta es la eliminación de cajas solapadas.
imgsz	• 1280 • 1920	Resolución de entrada usada para la inferencia. Resoluciones mayores mejoran la detección de personas pequeñas, pero aumentan el costo computacional.
PROXIMITY_THRESHOLD	• 100 • 150 • 200	Distancia mínima (en píxeles) entre una persona y el borde del polígono de la estación para considerarla "dentro" o "fuera". Valores mayores permiten más

		tolerancia para evitar falsos negativos. Usado en las reglas de trayectorias **Tabla 4-3**.
MIN_TIME_OUTSIDE	• 1.0 seg • 1.5 seg • 2.0 seg	Tiempo mínimo que una persona debe permanecer fuera de la estación para contar como evasión. Ayuda a filtrar detecciones momentáneas o errores del tracker. Usado en las reglas de trayectorias **Tabla 4-3**.
tracker	• bytetrack.yaml • botsort.yaml	Algoritmo de tracking utilizado para asignar IDs y mantener el seguimiento a lo largo del video. ByteTrack es más ligero; BoTSORT mejora el seguimiento en escenas densas y condiciones complejas. Detalles de cada tracker en la **Tabla 4-2**.

Fuente: Elaboración propia

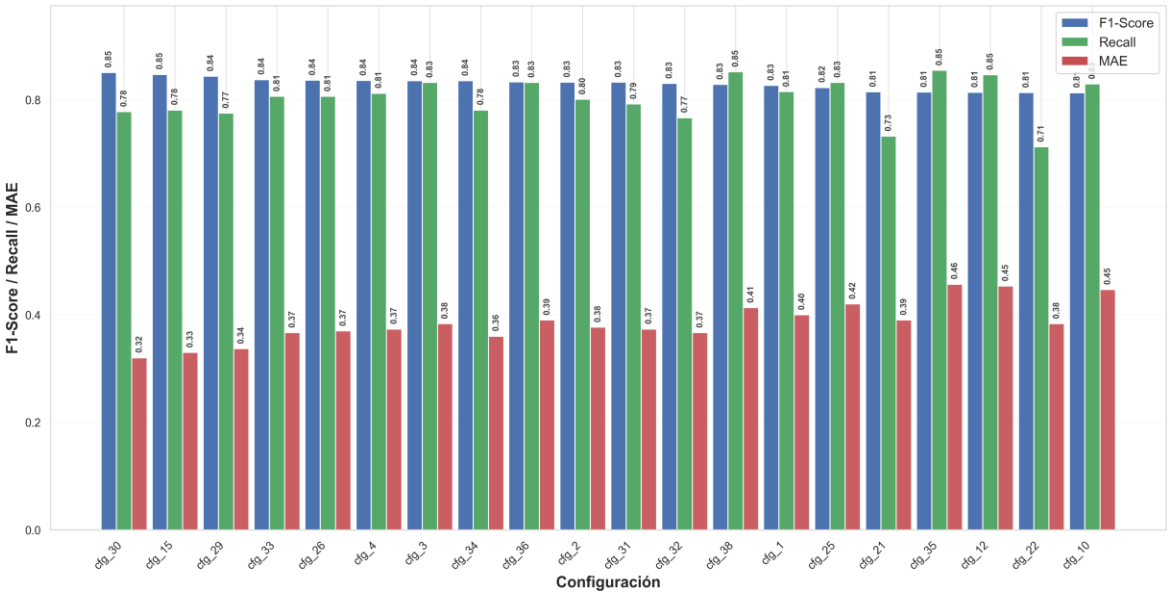
Al explorar las 40 configuraciones, se determinó que la mejor forma de evaluar el rendimiento era mediante el F1-score, ya que ofrece un equilibrio entre Precisión y Recall. Esta métrica resulta especialmente relevante porque la tarea consiste en detectar y contar eventos de evasión en videos, donde es importante evitar tanto las falsas alarmas como dejar pasar casos reales. Una precisión alta ayuda a reducir falsos positivos, mientras que un Recall alto evita perder eventos de evasión. Dado que las clases están desbalanceadas y ambos tipos de error son costosos, el F1-score se convierte en la medida más adecuada para comparar las configuraciones.

Figura 4-14 Gráfica del F1-Score para cada una de las configuraciones exploradas



Fuente: Elaboración propia

Figura 4-15 Ranking de las 20 mejores configuraciones exploradas



Fuente: Elaboración propia

En la **Figura 4-14** podemos observar el F1-score para cada una de las 40 combinaciones, en esta, la #30 fue la que obtuvo un mejor rendimiento, esto lo podemos ver mejor en la **Figura 4-15** donde no solo se muestra el F1-Score, sino también el recall y el error medio absoluto. Con esto podemos ver que el método tiene un buen desempeño a la hora de determinar cuando hay evasión y contar los casos presentes en un clip, estos clips no tienen límite de tiempo ya que se hicieron pruebas con los clips de 20 segundos, pero también con videos completos de hasta 20 minutos.

4.5.1 Análisis de la Mejor Configuración

La configuración 30 cuenta con los siguientes parámetros:

Tabla 4-5 Atributos de la mejor configuración explorada

Atributo	Valor
person_model	yolo11m.pt
person_conf	0.35
person_iou	0.4
tracker	botsort.yaml
imgsz	1280
station_model	stationv1.pt
PROXIMITY_THRESHOLD	50
MIN_TIME_OUTSIDE	1 seg

Fuente: Elaboración propia

Esta configuración utiliza el modelo YOLO11m combinado con BoT-SORT y con el modelo de detección de la estación completa. Esto tiene sentido porque, en los experimentos manuales, el modelo que solo detectaba hasta la plataforma aumentaba el riesgo de falsos positivos. En varias pruebas se observó que algunas personas se asoman hacia la calle y luego regresan rápidamente a la estación, lo cual podía interpretarse erróneamente como

una evasión. Al usar el modelo de la estación completa, ese riesgo disminuye de forma significativa.

El valor de confianza para la detección de personas (person_conf = 0.35) es relativamente bajo, pero esto es apropiado para el caso. Durante las pruebas se observó que, cuando las personas adoptan poses inusuales o llevan objetos que cubren parcialmente su cuerpo, las detecciones tienden a bajar de confianza. Mantener este valor bajo permitió conservar detecciones consistentes durante la secuencia de subida al bus. En todos los experimentos, este valor no generó problemas: el sistema siguió detectando correctamente a las personas.

El valor de person_iou = 0.4 ayuda a manejar mejor las personas solapadas, lo cual es importante porque uno de los patrones más comunes en este proyecto es que, cuando varias personas suben al bus, tienden a agruparse cerca de la entrada de la estación. Esto hace más difícil separarlas correctamente, pero con este umbral las cajas se procesan mejor y se evitan supresiones excesivas.

En cuanto a la resolución, esta configuración no usa un tamaño de entrada tan alto. Esto también tiene sentido porque, al utilizar una resolución de 1920, se detectaban personas en pasos peatonales o zonas externas al final de la estación que no eran relevantes, lo que incrementaba el riesgo de falsos positivos. Reducir la resolución ayuda a limitar el área efectiva de detección a la escena central sin afectar significativamente el desempeño dentro de la estación.

El tracker ganador fue BoT-SORT, lo cual es consistente con su diseño: este tracker funciona mejor en escenas densas y con múltiples personas interactuando, que es justamente lo que ocurre en muchos casos de evasión, especialmente en horas pico cuando ingresan varias personas al mismo tiempo.

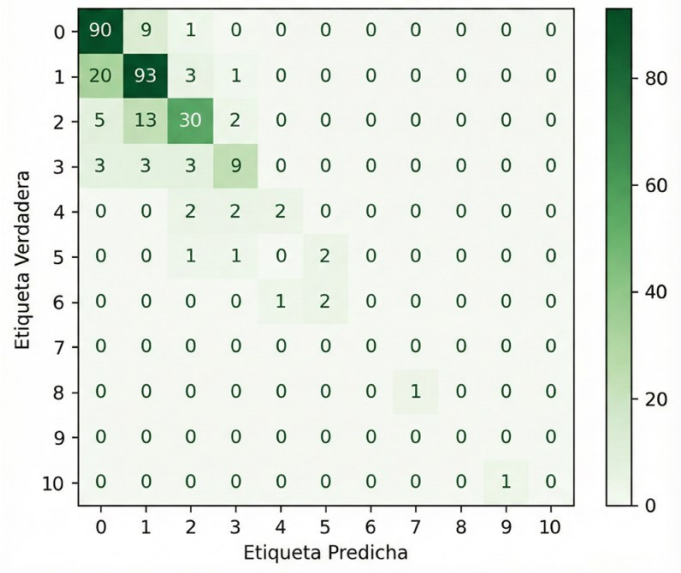
Con respecto a los parámetros de comportamiento, un PROXIMITY_THRESHOLD de 50 píxeles fue suficiente para determinar la cercanía de una persona al polígono de la estación.

Un MIN_TIME_OUTSIDE de 1 segundo funcionó bien para discriminar entre comportamientos normales y potenciales evasiones. Estos valores relativamente bajos tienen sentido porque se está utilizando el polígono de toda la estación, lo que reduce los casos donde las personas se mueven de forma natural cerca del límite entre la estación y la calle sin que eso represente una evasión real.

4.5.2 Rendimiento de la Mejor Configuración

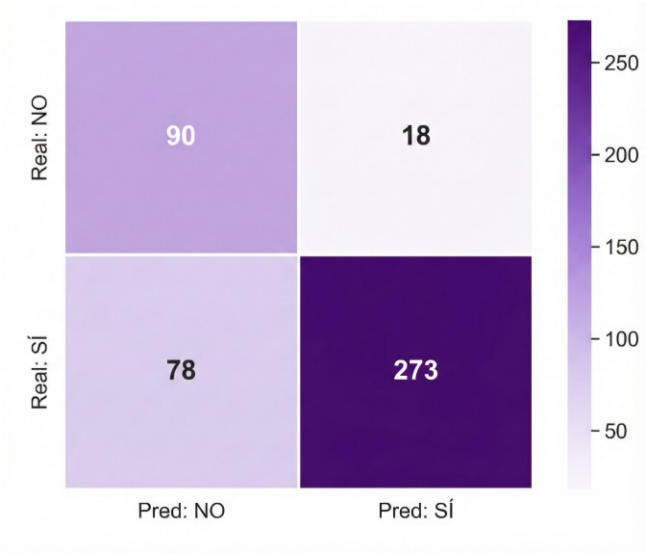
Al ejecutar el grid search, se obtuvo un dataset por cada configuración, en el cual se almacenaron tanto algunas métricas como las predicciones del método junto con algunos metadatos de cada clip. Inicialmente se generó la matriz de confusión basada en conteos presentada en la **Figura 4-16**, donde se compara el resultado con los conteos reales. En esta matriz se observa que las predicciones se encuentran cercanas a la diagonal, lo que permite concluir de manera preliminar que el modelo presenta un buen desempeño.

Figura 4-16 Matriz de confusión de conteos exactos para la mejor configuración



Fuente: Elaboración propia

Figura 4-17 Matriz de confusión por eventos de evasión para la mejor configuración



Fuente: Elaboración propia

La

Figura 4-17 presenta una matriz de confusión basada en eventos de evasión (sección **2.1**), construida a partir de la matriz basada en conteos exactos mostrada en la **Figura 4-16**, con el objetivo de examinar con mayor detalle el rendimiento del método. Esta nueva matriz se calculó a partir de las diferencias entre la cantidad real de evasiones y las predicciones del modelo; por ejemplo, si un clip contenía 6 evasores y el modelo predijo 5, se contabilizan 5 verdaderos positivos y un falso negativo. De forma similar, si un video no presentaba evasión y el método tampoco detectaba ninguna, se anotaban verdaderos negativos; mientras que, si el video no tenía evasión y el modelo reportaba alguna o presentaba más de las reales, se registraban falsos positivos. La matriz basada únicamente en conteos totales por video no refleja adecuadamente el desempeño del modelo, ya que exige una coincidencia exacta en el total de evasores. En cambio, transformar las diferencias entre el conteo real y el predicho en verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos, nos permite evaluar el rendimiento por cada persona que evade,

proporcionando métricas más precisas y evitando penalizar en exceso al método cuando falla por pocos casos en videos con múltiples evasiones.

Con esta matriz se calcularon métricas más precisas presentadas en la siguiente tabla:

Tabla 4-6 Métricas de evaluación de la mejor combinación de parámetros

Precision	Recall	F1-Score	Accuracy	MAE
0.9381	0.7778	0.8505	0.7908	0.320

Fuente: Elaboración propia

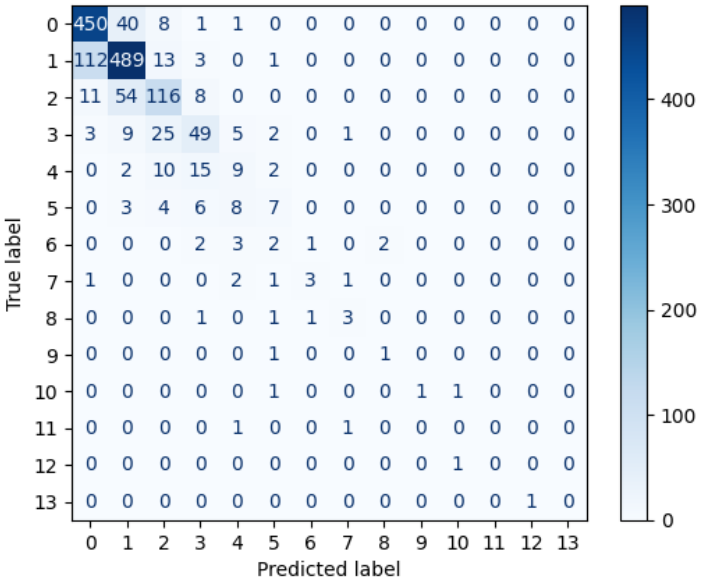
Estas métricas obtenidas muestran un desempeño sólido en esta configuración de parámetros. La Precision (0.9381) indica que la mayoría de las evasiones detectadas son correctas, mientras que el Recall (0.7778) evidencia que aún se dejan pasar algunos casos reales, reflejando la presencia de falsos negativos. El F1-Score (0.8505) confirma un equilibrio adecuado entre ambas métricas, y la Accuracy (0.7908) sugiere un comportamiento global consistente. Por su parte, el MAE (0.320) muestra que el error absoluto en el conteo es bajo, y el porcentaje de conteos exactos (75.33%) basado en la matriz de conteos exactos, indica que el método acierta completamente en una proporción considerable de los casos.

Alcanzar estos valores es particularmente destacable considerando que los videos de las cámaras de los vagones presentan múltiples situaciones y comportamientos de las personas que incluso pueden dificultar que un observador humano logre un conteo exacto de los evasores.

5. Resultados

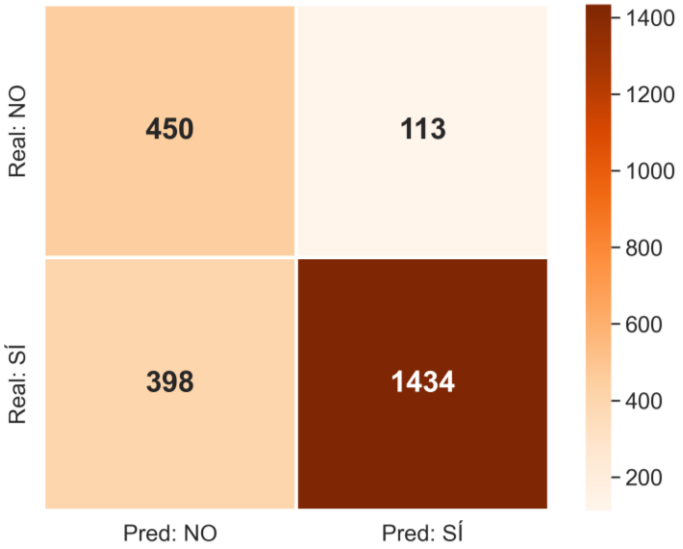
Para la validación final del método se utilizó un conjunto de datos compuesto por 1.500 videos, seleccionados para representar diversos escenarios operativos. De estos, 1.000 videos presentaban al menos un evento de evasión y 500 no presentaban ninguno. Esta distribución permitió evaluar no solo la capacidad del método para detectar la evasión, sino también su habilidad para evitar generar falsas alarmas. Para esta etapa se empleó la configuración óptima identificada durante la exploración de parámetros, la cual integra el detector YOLO11m, el algoritmo de rastreo BoT-SORT y el modelo de detección de estación completa. Los detalles de esta configuración se presentan en la **Tabla 4-5**.

Figura 5-1 Matriz de confusión de conteos exactos en la validación final



Fuente: Elaboración propia

Figura 5-2 Matriz de confusión por eventos de evasión en la validación final



Fuente: Elaboración propia

Tabla 5-1 Métricas de la evaluación final

Precision	Recall	F1-Score	Accuracy	MAE
0.9270	0.7828	0.8488	0.7866	0.341

Fuente: Elaboración propia

Al procesar el conjunto de datos, se obtuvieron las métricas de desempeño detalladas en la **Tabla 5-1**. El método logró detectar 1434 de los 1832 eventos de evasión.

5.1 Análisis de la Matriz de Confusión

Para comprender mejor el comportamiento del método, se desglosan los resultados en los cuatro cuadrantes fundamentales de la detección:

- **Verdaderos Positivos (TP) - 1434**: Representan la cantidad de evasores que el sistema identificó, rastreó y clasificó correctamente aplicando el análisis de las trayectorias especificado en la sección **4.3.5**.
- **Falsos Positivos (FP) – 113**: Detecciones erróneas donde el sistema contabilizó una evasión inexistente. Este número es bajo comparado con el volumen total de videos, lo que sugiere que la lógica de filtrado por ROI y dirección es efectiva. Los casos registrados se deben a situaciones poco comunes donde se detectaron personas ingresando desde el bus hacia la estación. Este aspecto se analiza a fondo en las secciones de alcance y trabajo futuro.
- **Falsos Negativos (FN) - 398**: Respecto a los falsos negativos (evasiones omitidas), el análisis cualitativo sugiere una fuerte correlación con oclusiones severas, particularmente cuando múltiples evasores ingresan en bloques compactos. Asimismo, las poses atípicas y los desplazamientos de alta velocidad afectaron la capacidad del tracker para mantener la asociación temporal entre fotogramas. Estos escenarios, predominantes en horas pico, representan un desafío de alta complejidad, dado que la densidad de usuarios dificulta la distinción individual incluso para un observador humano.
- **Verdaderos Negativos (TN) - 450**: En el contexto de los 500 videos de control (sin evasión), el método procesó perfectamente 450 de ellos, reportando cero evasiones.

5.2 Análisis de Métricas de Rendimiento

El método desarrollado muestra un rendimiento bastante bueno, como lo demuestran las métricas obtenidas. Con una precisión de 0.9270, se concluye que la mayoría de las evasiones que el sistema detecta son casos reales, lo que se traduce en una baja tasa de falsas alarmas. Por otro lado, el Recall de 0.7828 indica que el método es capaz de identificar una parte significativa de las evasiones reales que aparecen en los videos, aunque todavía hay

algunos casos que se escapan. El equilibrio entre estas métricas se refleja en el F1-score de 0.8488, lo que demuestra un rendimiento sólido en un contexto donde las clases están desbalanceadas, y donde tanto los falsos positivos como los falsos negativos son importantes para este trabajo. La Precision de 0.7866 respalda esta tendencia.

Por último, el MAE de 0.341 sugiere que, en promedio, el error en el conteo de evasiones por video es bajo, lo que implica que el método no solo detecta adecuadamente los eventos de evasión, sino que también estima de manera razonable la cantidad de evasiones presentes.

Con la matriz de confusión de conteos exactos se encontró que en el 75% de los videos (1125 de 1500) usados para validar el método, este fue capaz de generar el conteo exacto al real. Con solo este valor base, se observa que el método tiene un buen desempeño para detectar casos de evasión y contabilizar el número de evasiones presentes en un video.

Este método demuestra una buena capacidad de determinar eventos de evasión, a pesar de los casos complejos que se observan generalmente. En el repositorio **"deteccion-de-evasion-en-sistemas-BRT"**[1] se encuentran ejemplos de videos procesados para los casos complejos y comunes observados.

En estos ejemplos se puede observar que el método es capaz de procesar los siguientes escenarios complejos y regulares:

- En los casos donde hay muchas personas entrando a la estación, presentando condiciones complejas no solo en ambiente sino también en comportamientos, se observa que el método es capaz de detectar la mayoría de evasores.

[1] https://github.com/FtxDJuan1214/deteccion-de-evasion-en-sistemas-BRT?tab=readme-ov-file#-ejemplos

- En casos donde la cámara está rotada, se observa que el método también es capaz de encontrar las personas, hacerles seguimiento y analizar si están entrando ilegalmente a la estación.
- En casos donde no hay evasión se observa como el método es robusto frente a situaciones donde pareciera que las personas van a entrar ilegalmente, pero en realidad no se comete evasión.
- En casos mixtos donde en la misma escena hay personas saliendo y entrando a la estación, el método fue capaz de discriminar en gran mayoría a los que estaban cometiendo evasión de los que no.

5.3 Alcance y Limitaciones

Durante el desarrollo del proyecto se identificaron diversas limitaciones, siendo la más crítica la complejidad inherente a los escenarios de alta densidad (horas pico). En estas situaciones, la concurrencia de múltiples eventos generó desafíos significativos:

- Oclusiones y Perspectiva: El ingreso simultáneo de evasores provocó oclusiones severas. Específicamente, cuando los sujetos caminan alineados al eje de la cámara, la perspectiva visual genera una superposición que impide distinguirlos individualmente.
- Dinámica de Movimiento: Las variaciones de velocidad y los cruces frecuentes entre personas dificultaron el seguimiento (tracking) continuo, propiciando la pérdida de identidades.
- Recursos Computacionales: Aunque la detección de poses es viable, su implementación requiere resoluciones de imagen superiores y un costo computacional que excedía los recursos disponibles.

Si bien el modelo YOLO demostró un desempeño notable, la resolución de estos casos borde (edge cases) requiere un tiempo de desarrollo y optimización que escapa al alcance

actual del proyecto. Por ello, se proponen estrategias específicas en la sección de **Trabajo Futuro** para abordar estas limitaciones y robustecer el método creado.

6. Conclusiones y Trabajo Futuro

6.1 Conclusiones

Se logró desarrollar e implementar un método de inteligencia artificial basado en visión por computadora capaz de detectar y cuantificar la evasión en las puertas de los vagones. El método final, operando sobre videos de vigilancia reales, alcanzó un F1-Score del 84.88%, demostrando ser una herramienta viable para automatizar una tarea que actualmente es importante para la toma de decisiones en los sistemas BRT.

La evaluación comparativa de tecnologías mediante la revisión de la literatura permitió identificar a YOLO como el mejor método para aplicar al contexto específico de este trabajo. Mas adelante en el desarrollo de este, se comprobó que no solo funcionaba para la detección de personas, sino que también fue efectivo para detectar la estación y hacer el tracking objetos.

Si bien el método desarrollado para la detección de evasión no alcanza una exactitud del 100 %, logra capturar la mayoría de los eventos de evasión. La estructura metodológica demostró ser efectiva durante la validación final, lo cual resulta destacable, ya que permitió superar diversos casos complejos presentes en las escenas de los videos tomados en las estaciones de TransMilenio. En este sentido, se concluye que las etapas de detección de personas, asignación de identificadores para el seguimiento de trayectorias y aplicación de reglas espaciales y temporales en función de la ubicación de la estación fueron adecuadas para abordar el problema planteado. Asimismo, la validación evidenció que el modelo no

solo identifica eventos de evasión, sino que también filtra el ruido operativo reduciendo falsos positivos, lo cual contribuye a la estabilidad y fiabilidad del sistema.

El método propuesto es transferible a otros sistemas BRT que cuenten con infraestructura basada en vagones, siempre que las condiciones de captura, particularmente el ángulo de las cámaras, sean similares a las empleadas en los videos del sistema TransMilenio.

6.2 Trabajo Futuro

Una oportunidad clara de optimización reside en la especialización del detector. Si bien YOLO11m ofrece un rendimiento destacado y útil en este proyecto, su capacidad para identificar personas en posturas no convencionales podría elevarse mediante un proceso de fine tuning con datos del dominio específico. Aunque en este trabajo se trató de implementar un fine tuning utilizando el dataset WiderPerson, la construcción de un conjunto de entrenamiento propio basado exclusivamente en fotogramas del entorno operativo real dotaría al método de una robustez superior, justificando la inversión de tiempo que requiere el etiquetado manual de estas nuevas muestras.

Otro punto de mejora consiste en refinar el análisis de trayectorias. Dado que el sistema actual ya genera trazas de seguimiento (tracks), es posible utilizar estos datos para minimizar la construcción de nuevos conjuntos de entrenamiento y validación que, por la experiencia en este proyecto, requieren una cantidad de tiempo considerable. Con esto, se pueden etiquetar las secuencias de evasión existentes para entrenar un modelo capaz de aprender patrones de desplazamiento anómalos, sustituyendo así las actuales reglas heurísticas espaciales y temporales por un clasificador basado en aprendizaje automático.

Un último aspecto para mejorar es el análisis de la llegada y partida de los buses para excluir a las personas que se encuentran dentro de ellos. En casos poco frecuentes donde el bus se detenía lejos de la plataforma, las personas eran detectadas como si estuvieran fuera

de la estación. Esto generaba un track que, sumado al tiempo que toma salir del vehículo, resultaba en una detección de ingreso ilegal. Para mitigar esto se puede implementar YOLO para discriminar las personas que están dentro de los buses.

Bibliografía

Barabino, B., Lai, C., & Olivo, A. (2020). A. Fare evasion in public transport systems: a review of the literature. *Public Transport*, 27–88.

Guzman, L. A., Arellana, J., & Camargo, J. P. (2021). A hybrid discrete choice model to understand the effect of public policy on fare evasion discouragement in Bogotá's Bus Rapid Transit. *Transportation Research Part A: Policy and Practice*, 140-153.

Burgos, E., Velásquez, E., & Rosero, L. (2018). *Sistema de tratamiento de imágenes con tecnologías IoT para el control y monitoreo: Caso de estudio evasión por puerta de vagón en las estaciones de TransMilenio.* Trabajo de grado, Bogotá.

TransMilenio S.A. (2022). *Diálogos ciudadanos 2022.* Obtenido de https://www.google.com/url?client=internal-element-cse&cx=01206783025583986 3893:tkgki0cslj0&q=https://www.transmilenio.gov.co/loader.php%3FlServicio%3D To ols2%26lTipo%3Ddescargas%26lFuncion%3Ddescargar%26idFile%3D51054&sa= U&ved=2ahUKEwjHkuPNyJCFAxU-toQI

TransMilenio S.A. (2024). *INFORME DE EVASIÓN EN EL COMPONENTE TRONCAL DE TRANSMILENIO 2024-I.* Obtenido de https://www.transmilenio.gov.co/loader.php?lServicio=Tools2&lTipo=descargas&l Funcion=visorpdf&file=https://www.transmilenio.gov.co/loader.php?lServicio%3 DTools2%26lTipo%3Ddescargas%26lFuncion%3DexposeDocument%26idFile%3D 59255%26tmp%3Ddf3fcf6232a237bd68f50

TransMilenio S.A. (2023b). *Informe de evasión en el componente troncal de TransMilenio 2023-II.* Obtenido de https://www.google.com/url?client=internal-element-cse&cx=01206783025583986 3893:tkgki0cslj0&q=https://www.transmilenio.gov.co/loader.php%3FlServicio%3D To

ols2%26lTipo%3Ddescargas%26lFuncion%3Dvisorpdf%26id%3D57267%26pdf%3D1&sa=U&ved=2ahUKEwjHkuPNyJCFAxU-

Bahamondes, B. M. (2019). *Estudio de un modelo de evasión en el transporte público.*

Cabanelas Omil, J. (2019). Inteligencia artificial ¿Dr. Jekyll o Mr. Hyde? *Mercados y Negocios*, 5-22.

Rouhiainen, L. (2018). Inteligencia artificial: 101 cosas que debes saber hoy sobre nuestro futuro. *Madrid: Alienta Editorial*.

de Titto, E., & Savino, A. (2023). Inteligencia artificial y ambiente.

Badillo, F., Hernández, C., Narváez, B., & Trillos, Y. (2021). Redes neuronales convolucionales: un modelo de Deep Learning en imágenes diagnósticas. Revisión de tema. *Revista colombiana de radiología*, 32.

Durán Suárez, J. (2017). *Redes neuronales convolucionales en R: Reconocimiento de caracteres escritos a mano.*

Bonilla Carrión, C. (2020). *Redes Convolucionales.* Universidad de Sevilla.

Rodríguez Peraza, C. I. (2024). *Detección y conteo de evasores en el sistema de transporte Transmilenio.* Universiada Nacional.

TransMilenio S.A. (2023a). *Informe de evasión en el componente troncal de TransMilenio 2022-II.* Obtenido de https://www.transmilenio.gov.co/loader.php?lServicio=Tools2&lTipo=descargas&lFuncion=descargar&idFile=53358

Ultralytics. (2025b). *Roboflow Integration*. Obtenido de Ultralytics Docs: https://docs.ultralytics.com/integrations/roboflow/

Ultralytics Inc. (2025a). *Instance segmentation*. Obtenido de Ultralytics Docs: https://docs.ultralytics.com/es/tasks/segment/

Ultralytics Inc. (2025e). *Pose Estimation*. Obtenido de Ultralytics YOLO Docs: https://docs.ultralytics.com/tasks/pose/

Ultralytics Inc. (2025c). *Object detection*. Obtenido de Ultralytics Docs: https://docs.ultralytics.com/es/tasks/detect/

Ultralytics Inc. (2025d). *Multi-Object Tracking with Ultralytics YOLO*. Obtenido de Ultralytics Docs: https://docs.ultralytics.com/modes/track/

Zhang, S. X. (2019). *WiderPerson: A diverse dataset for dense pedestrian detection in the wild.* Obtenido de arXiv: https://arxiv.org/pdf/1909.12118

Chavan, S. A., Chaudhari, N. M., & Ramteke, R. J. (2023). Analyzing the Performance of Object Detection and Tracking Techniques. En *Lecture Notes in Networks and Systems* (págs. 467–474).

Purwono, P., Ma'arif, A., Rahmaniar, W., Fathurrahman, H. I., Frisky, A. Z., & Haq, Q. M. (2023). Understanding of Convolutional Neural Network (CNN): A Review. *International Journal of Robotics and Control Systems, 2*(4), 739–748.

Jeevidha, S., Saraswathi, S., & Vishnuprasad. (2023). Contextual learning in Video Analytics for Human pose Detection using Bayesian Learning and LSTM. *2023 International Conference on Networking and Communications (ICNWC)*, (págs. 1–6).

Pal, S. K., Pramanik, A., Maiti, J., & Mitra, P. (2021). Deep learning in multi-object detection and tracking: state of the art. *Applied Intelligence, 51*(9), 6400–6429.

Ma, Y., & Salcic, Z. (2021). Deep learning with accelerated execution: toward a real-time video analysis system. *Neural Computing and Applications, 33*(24), 17407–17424.

Valarmathi, B., Kshitij, J., Dimple, R., Srinivasa Gupta, N., Harold Robinson, Y., Arulkumaran, G., & Mulu, T. (2023). Human Detection and Action Recognition for Search and Rescue in Disasters Using YOLOv3 Algorithm. *Journal of Electrical and Computer Engineering*.

Gündüz, M. Ş., & Işık, G. (2023). A new YOLO-based method for real-time crowd detection from video and performance analysis of YOLO models. *Journal of Real-Time Image Processing, 20*(1), 5.

Augusta Kani, G., & Geetha, P. (2023). Adaptive Weighted Flow Net Algorithm for Human Activity Recognition Using Depth Learned Features. *Computer Systems Science and Engineering, 46*, 1447–1469.

Hsiao, S.-F., & Tsai, C.-Y. (2018). Design and Implementation of Low-Cost LK Optical Flow Computation for Images of Single and Multiple Levels. *2018 21st Euromicro Conference on Digital System Design (DSD)*, (págs. 276–279).

Yang, G., & Chen, Z. (2019). Pedestrian Tracking Algorithm for Dense Crowd based on Deep Learning. *2019 6th International Conference on Systems and Informatics (ICSAI)*, (págs. 568-572). Shanghai.

Nguyen, T. P., Pham, C. C., Ha, S. V.-U., & Jeon, J. W. (2019). Change Detection by Training a Triplet Network for Motion Feature Extraction. *IEEE Transactions on Circuits and Systems for Video Technology*, 433–446.

Ghaywate, P., Vyas, F., Telang, S., & Mangale, S. (2019). A Deep Learning Approach for Motion Segmentation Using An Optical Flow Technique. *2019 10th International Conference on Computing, Communication and Networking Technologies (ICCCNT)* (págs. 1–6). Kanpur, India: IEEE.

Hanavi, & Hidayat, F. (2020). Intelligent Video Analytic for Suspicious Object Detection : A Systematic Review. *2020 International Conference on ICT for Smart Society (ICISS)*, (págs. 1-8).

Padhi, A., Sahoo, G., & Maity, S. (2021). Intelligent Intrusion Detection Using TensorFlow. En *Smart Innovation, Systems and Technologies* (Vol. 153, págs. 653–662). Singapore: Springer.

Challa, R., & Rao, K. S. (2021). Hybrid Approach for Detection of Objects from Images Using Fisher Vector and PSO Based CNN. *Ingénierie Des Systèmes d Information, 26*(5), 483–489.

Zhang, T., Aftab, W., Mihaylova, L., Langran-Wheeler, C., Rigby, S., Fletcher, D., . . . Bosworth, G. (2022). Recent Advances in Video Analytics for Rail Network Surveillance for Security, Trespass and Suicide Prevention—A Survey. *Sensors, 22*(12), 4324.

Liu, S., Li, Q., Ji, H., Wang, L., Zhang, X., & He, Z. (2022). A Novel YOLOv5-based Anomalous Object Detection Algorithm in Buses.

Li, Y. (2022). Moving object detection for unseen videos via truncated weighted robust principal component analysis and salience convolution neural network. *Multimedia Tools and Applications, 81*(23), 32779–32790.

Adimoolam, M., Mohan, S., A., J., & Srivastava, G. (2022). A Novel Technique to Detect and Track Multiple Objects in Dynamic Video Surveillance Systems. *International Journal of Interactive Multimedia and Artificial Intelligence, 7*(4), 112.

Kumar, M., & Bhatt, R. (2022). An approach towards Real-Time Object Detector Using Open CV. *2022 11th International Conference on System Modeling & Advancement in Research Trends (SMART)*, 981–985.

Gupta, C., Tripura, G., Teja, G., Veginati, H., Samidurai, S., & Kuchibhotla, S. (2023). Improved Human Detection and Classification using Supervised Machine Learning Algorithms. *ICCES*, (págs. 1045-1050).

Wang, Y., Mao, K., Chen, T., Yin, Y., He, S., & Chen, G. (2021). Accelerating real-time object detection in high-resolution video surveillance. *Concurrency and Computation: Practice and Experience, 35*, 2021.

Ghahremannezhad, H., Shi, H., & Liu, C. (2023). Object Detection in Traffic Videos: A Survey. *IEEE Transactions on Intelligent Transportation Systems, 24*(7), 6780–6799.

Host, K., Pobar, M., & Ivasic-Kos, M. (2023). Analysis of Movement and Activities of Handball Players Using Deep Neural Networks. *Journal of Imaging, 9*(4), 80.

Kim, G.-I., Yoo, H., & Chung, K. (2023). SlowFast Based Real-Time Human Motion Recognition with Action Localization. *Computer Systems Science and Engineering, 47*(2), 2135–2152.